

TALLER PRÁCTICO

Diferencias Finitas y Monte Carlo en la Valoración de Derivados Exóticos

Modelo Markov-modulado con tasas distintas por régimen

Métodos Numéricos en Finanzas

OSCAR JAVIER LÓPEZ ALFONSO

Implementación en Python • Esquema θ • Enfoque integral de Zheng-Zhu & Técnicas Monte Carlo

14 de mayo de 2026

Índice

1	Objetivos del taller	3
2	Recordatorio extendido del modelo	3
2.1	Cadena de Markov subyacente	4
2.2	Dinámica del activo riesgoso	4
2.3	Cambio a la medida martingala	4
2.4	El factor de descuento bajo tasas dependientes del régimen	4
2.5	Sistema acoplado de PDEs	5
2.6	Condiciones de frontera por tipo de opción	5
3	Diferencias finitas para opciones europeas	6
3.1	Discretización espacial y temporal	6
3.2	Condiciones de frontera para la put europea	7
3.3	Esquema θ y sistema lineal por bloques	8
3.4	Implementación	9
4	Opciones americanas: enfoque integral de Zheng–Zhu	11
4.1	Formulación con frontera libre y adimensionalización	12
4.2	Transformada de Fourier incompleta	13
4.3	Sistema matricial en Fourier	13
4.4	Matriz fundamental: exponencial cerrada para 2×2	14
4.5	Tratamiento de raíces cuasi-dobles (Proposición 1 del paper)	14
4.6	Ecuaciones integrales para frontera libre y precio	15
4.7	Implementación: ladrillos algebraicos	15
4.8	Benchmark ejecutable: PSOR para la PDE acoplada	17
4.9	Ejercicio avanzado opcional: discretización de las ecuaciones integrales	20
5	Opciones asiáticas europeas con promedio aritmético	20
5.1	Formulación del problema	21
5.2	Reducción de similaridad de Rogers–Shi adaptada al régimen	21
5.3	Dificultades numéricas de la reducción	22
5.4	Monte Carlo: el método ejecutable	23
5.5	Resultados numéricos	25
5.6	Opciones exóticas: forward start y chooser	25
5.6.1	Reducción de varianza: marco general	25
5.6.2	Forward start option	26
5.6.3	Chooser option	28
5.6.4	Síntesis de las dos técnicas	30
5.7	Ejercicio diagnóstico: FD 1D y sus limitaciones	31
6	Experimentos numéricos y comparación	32
6.1	Parámetros base y tabla maestra de precios	32
6.2	Efecto del spread $r_1 - r_0$ sobre el precio europeo	33
6.3	Prima americana: dependencia del régimen y del vencimiento	33
6.4	Tiempos de cómputo	34
6.5	Guía rápida: cuándo usar qué método	35

7 Preguntas de reflexión	36
A Resumen de fórmulas clave	37

1. Objetivos del taller

Este taller es la continuación natural del Taller 2 sobre valoración por transformada de Fourier en el modelo Markov-modulado. Ahora levantamos la restricción $r_0 = r_1$ y, al hacerlo, perdemos la factorización del descuento que hacía posibles los métodos de Carr–Madan y COS. La consecuencia es que debemos resolver el sistema acoplado de ecuaciones diferenciales parciales directamente, lo cual abre además la puerta a opciones con derechos de ejercicio anticipado (americanas) y opciones dependientes de la trayectoria (asiáticas).

Al finalizar el taller el estudiante:

1. Comprenderá por qué el factor de descuento $\exp\left(-\int_0^T r_{\varepsilon(s)} ds\right)$ no admite factorización fuera de la esperanza cuando $r_0 \neq r_1$, y por tanto los métodos de transformada del Taller 1 dejan de aplicarse de forma directa.
2. Implementará el sistema acoplado de PDEs de Black–Scholes–Markov por el método θ (con énfasis en Crank–Nicolson) y validará la implementación contra los precios FFT/-COS del Taller 2 en el caso $r_0 = r_1$.
3. Valorará opciones **put americanas** en el modelo Markov-modulado mediante el enfoque integral de Zheng & Zhu (2025): transformada de Fourier incompleta, reducción a un sistema de ODEs en el espacio de Fourier, y desacoplamiento estado por estado vía la descomposición espectral de la matriz $C(\eta)$. Como método ejecutable validable, implementará PSOR sobre la PDE acoplada.
4. Tratará el caso (numéricamente delicado) de raíces dobles o cuasi-dobles del polinomio característico de $C(\eta)$, siguiendo la Proposición 1 del artículo.
5. Valorará opciones **asiáticas europeas** (con promedio aritmético y strike fijo) deduciendo la reducción de similitud de Rogers–Shi adaptada al régimen, identificando las dificultades numéricas que la implementación FD presenta, y resolviendo el problema mediante **Monte Carlo**.
6. Aplicará Monte Carlo a opciones **exóticas path-dependent** (forward start y chooser) en el modelo Markov-modulado, utilizando dos técnicas clásicas de *reducción de varianza*: **Conditional Monte Carlo** para la forward start (aprovechando la homogeneidad de grado 1 del precio en S) y **Control Variate** con *Common Random Numbers* para el chooser (usando la fórmula cerrada de Rubinstein como ancla).
7. Comparará precisión, eficiencia y rango de aplicabilidad de los cuatro enfoques numéricos del taller: diferencias finitas para la PDE acoplada, ecuación integral de Zheng–Zhu y PSOR para americanas, Monte Carlo para asiáticas y exóticas, y — como referencia heredada del Taller 2 — FFT/COS en el caso $r_0 = r_1$.

2. Recordatorio extendido del modelo

Conservamos la notación del Taller 2, con un único cambio sustancial: ahora las tasas libres de riesgo dependen del régimen.

2.1 Cadena de Markov subyacente

Definición — Cadena de Markov (sin cambios respecto al Taller 2)

Sea $\varepsilon = \{\varepsilon(t)\}_{t \geq 0}$ una cadena de Markov en tiempo continuo con espacio de estados $\{0, 1\}$ y matriz generadora

$$Q = \begin{pmatrix} -\lambda_0 & \lambda_0 \\ \lambda_1 & -\lambda_1 \end{pmatrix}, \quad \lambda_0, \lambda_1 > 0.$$

El tiempo de permanencia en el estado i es exponencial con parámetro λ_i , y la distribución estacionaria viene dada por

$$\pi_0 = \frac{\lambda_1}{\lambda_0 + \lambda_1}, \quad \pi_1 = \frac{\lambda_0}{\lambda_0 + \lambda_1}.$$

2.2 Dinámica del activo riesgoso

Bajo la medida física $\mathbb{P}$, el precio del activo satisface

$$dS_t = S_t \mu_{\varepsilon(t)} dt + S_t \sigma_{\varepsilon(t)} dW_t, \quad S_0 > 0,$$

donde W es un movimiento Browniano estándar independiente de ε . En cada régimen $i \in \{0, 1\}$ los parámetros son μ_i (drift), σ_i (volatilidad) y r_i (tasa libre de riesgo).

Cambio respecto al Taller 2

En el Taller 2 trabajamos con la simplificación $r_0 = r_1 = r$ para mantener la factorización del descuento. En este taller permitimos $r_0 \neq r_1$, lo cual es la situación realista: una recesión y una expansión típicamente coexisten con tasas de política monetaria distintas.

2.3 Cambio a la medida martingala

Mediante el teorema de Girsanov con precio de riesgo $\theta_i = (\mu_i - r_i)/\sigma_i$, se construye la medida $\mathbb{Q}$ bajo la cual

$$dS_t = S_t r_{\varepsilon(t)} dt + S_t \sigma_{\varepsilon(t)} dW_t^{\mathbb{Q}}.$$

Como en el Taller 2, la cadena ε conserva su ley bajo $\mathbb{Q}$ (mismas intensidades λ_0, λ_1); el cambio de medida solo afecta la componente Browniana. Recordemos que en mercados con regímenes el cambio de medida no es único — aquí adoptamos por defecto la medida vía Esscher o, equivalentemente, la implícita en la sustitución $\mu_i \mapsto r_i$.

2.4 El factor de descuento bajo tasas dependientes del régimen

Aquí está la observación pedagógica clave que motiva todo el taller. Para una opción europea con payoff $\Phi(S_T)$, el precio bajo $\mathbb{Q}$ condicional a $\varepsilon(0) = i$ es

$$V_i(S_0, 0) = \mathbb{E}_i^{\mathbb{Q}} \left[\exp \left(- \int_0^T r_{\varepsilon(s)} ds \right) \Phi(S_T) \right].$$

Observación clave — Por qué falla la factorización

Cuando $r_0 = r_1 = r$, el integrando $\int_0^T r_{\varepsilon(s)} ds$ se reduce a rT y el factor de descuento e^{-rT} sale de la esperanza:

$$V_i(S_0, 0) = e^{-rT} \mathbb{E}_i^Q[\Phi(S_T)].$$

Esto es lo que permite trabajar limpiamente con la función característica $\varphi_i^Q(z, T)$ y los métodos Carr–Madan/COS del Taller 1.

Cuando $r_0 \neq r_1$, la variable aleatoria $\int_0^T r_{\varepsilon(s)} ds$ es *no degenerada* y depende de la trayectoria completa de ε en $[0, T]$. El factor de descuento queda enredado con el payoff dentro de la esperanza, y *no existe* una expresión cerrada del precio en términos de $\varphi_i^Q(z, T)$ análoga a la de Carr–Madan. Esto responde directamente la pregunta (b) del Ejercicio 14 del Taller 2.

La salida estándar es resolver la PDE de valoración. Por la propiedad de Markov conjunta de $(S_t, \varepsilon(t))$, el precio $V_i(S, t)$ del derivado en el régimen i satisface una PDE de tipo Black–Scholes con un término de acoplamiento debido a los saltos de régimen.

2.5 Sistema acoplado de PDEs**Sistema acoplado — Black–Scholes–Markov**

Los precios $V_0(S, t)$ y $V_1(S, t)$ satisfacen el sistema acoplado de PDEs lineales parabólicas:

$$\frac{\partial V_i}{\partial t} + r_i S \frac{\partial V_i}{\partial S} + \frac{\sigma_i^2 S^2}{2} \frac{\partial^2 V_i}{\partial S^2} + \lambda_i (V_{1-i} - V_i) - r_i V_i = 0, \quad i = 0, 1, \quad (1)$$

en $(S, t) \in (0, \infty) \times [0, T)$, con condición terminal

$$V_i(S, T) = \Phi(S), \quad i = 0, 1,$$

donde Φ es el payoff. Las condiciones de frontera en $S = 0$ y $S \rightarrow \infty$, así como las restricciones adicionales para opciones americanas, se especifican según el contrato (ver Sección 2.6).

Interpretación financiera del término de acoplamiento

El término $\lambda_i (V_{1-i} - V_i)$ refleja el riesgo de transición de régimen: con tasa instantánea λ_i , el mercado salta al régimen complementario, donde el valor del derivado pasa de V_i a V_{1-i} . La diferencia $V_{1-i} - V_i$ es el “salto” en valoración asociado al cambio de régimen, y multiplicada por la intensidad λ_i da la contribución esperada a la deriva infinitesimal del precio. Esto responde la pregunta (e) del Ejercicio 14 del Taller 2.

2.6 Condiciones de frontera por tipo de opción

A lo largo del taller resolveremos tres problemas con la misma PDE (1) pero condiciones de frontera distintas.

Put europea. Payoff $\Phi(S) = (K - S)^+$. Condiciones:

$$V_i(0, t) = K e^{-r_i(T-t)} \cdot (\text{ajuste de régimen}), \quad \lim_{S \rightarrow \infty} V_i(S, t) = 0.$$

(El factor de ajuste de régimen es la solución exacta del subproblema en $S = 0$, que detallaremos en la Sección 3.)

Put americana. Payoff inicial $\Phi(S) = (K - S)^+$. Adicionalmente, el sistema (1) se cumple solo en la región de continuación $\{S > P_i(t)\}$, donde $P_i(t)$ es el *precio óptimo de ejercicio* en el régimen i , y se imponen las condiciones de *value matching* y *smooth pasting*:

$$V_i(P_i(t), t) = K - P_i(t), \quad \left. \frac{\partial V_i}{\partial S} \right|_{S=P_i(t)} = -1.$$

La frontera libre $P_i(t)$ es desconocida y se determina como parte de la solución. Tendremos *dos* fronteras libres acopladas, una por régimen.

Asiática europea (promedio aritmético, strike fijo). Sea $A_t = \int_0^t S_u du$ la integral del precio. El payoff es

$$\Phi(S_T, A_T) = \left(\frac{A_T}{T} - K \right)^+.$$

Ahora el precio $V_i(S, A, t)$ depende de *dos* variables de estado, y la PDE se modifica para incorporar la dinámica determinista $dA_t = S_t dt$. En la Sección 5 mostraremos que — gracias a la linealidad del acoplamiento $\lambda_i(V_{1-i} - V_i)$ en V_i — la reducción de similaridad de Rogers–Shi sobrevive al régimen y reduce el problema a un sistema 1D acoplado.

Con esto cerramos el recordatorio. Las próximas secciones desarrollan los tres enfoques numéricos.

3. Diferencias finitas para opciones europeas

Esta sección monta la maquinaria de diferencias finitas que reutilizaremos a lo largo del taller. El objetivo es triple: (i) resolver el sistema acoplado de PDEs (1) con un esquema θ , (ii) validar la implementación contra los métodos FFT/COS del Taller 2 cuando $r_0 = r_1$, y (iii) tener un baseline numérico contra el cual contrastar el enfoque integral de Zheng–Zhu en la Sección 4.

Por consistencia con la Sección 4 y el artículo de referencia, trabajaremos con la **put europea** con payoff $\Phi(S) = (K - S)^+$. La adaptación a una call es inmediata (solo cambian la condición terminal y las condiciones de frontera).

3.1 Discretización espacial y temporal

Cambio de variable temporal. Conviene invertir el tiempo introduciendo $\tau = T - t$ para convertir el problema con condición terminal en uno con condición inicial. Definiendo $\tilde{V}_i(S, \tau) := V_i(S, T - \tau)$, el sistema (1) se reescribe como

$$\frac{\partial \tilde{V}_i}{\partial \tau} = r_i S \frac{\partial \tilde{V}_i}{\partial S} + \frac{\sigma_i^2 S^2}{2} \frac{\partial^2 \tilde{V}_i}{\partial S^2} + \lambda_i (\tilde{V}_{1-i} - \tilde{V}_i) - r_i \tilde{V}_i, \quad \tau \in (0, T], \quad (2)$$

con condición inicial $\tilde{V}_i(S, 0) = \Phi(S)$. En lo que sigue suprimimos la tilde.

Grilla. Truncamos el dominio espacial a $[0, S_{\max}]$ con $S_{\max}$ varias veces mayor que el strike (en la práctica $S_{\max} \in [3K, 5K]$ es suficiente para opciones cerca del dinero). Usamos una grilla uniforme:

$$S_j = j \Delta S, \quad j = 0, 1, \dots, M, \quad \Delta S = \frac{S_{\max}}{M},$$

y particionamos $[0, T]$ uniformemente:

$$\tau_n = n \Delta\tau, \quad n = 0, 1, \dots, N_t, \quad \Delta\tau = \frac{T}{N_t}.$$

Denotamos $V_i^{n,j} \approx V_i(S_j, \tau_n)$.

Coefficientes. Usando diferencias centradas para las derivadas espaciales en $S = S_j$,

$$\left. \frac{\partial V_i}{\partial S} \right|_{S_j} \approx \frac{V_i^{j+1} - V_i^{j-1}}{2 \Delta S}, \quad \left. \frac{\partial^2 V_i}{\partial S^2} \right|_{S_j} \approx \frac{V_i^{j+1} - 2V_i^j + V_i^{j-1}}{(\Delta S)^2},$$

y notando que $S_j / \Delta S = j$, el lado derecho de (2) en el nodo j queda

$$\frac{dV_i^j}{d\tau} = a_i^j V_i^{j-1} + b_i^j V_i^j + c_i^j V_i^{j+1} + \lambda_i V_{1-i}^j, \quad (3)$$

con los coeficientes

$$a_i^j = \frac{\sigma_i^2 j^2}{2} - \frac{r_i j}{2}, \quad b_i^j = -\sigma_i^2 j^2 - r_i - \lambda_i, \quad c_i^j = \frac{\sigma_i^2 j^2}{2} + \frac{r_i j}{2}. \quad (4)$$

Observación numérica. Cuando $\sigma_i^2 j^2 < r_i j$ (es decir, $j < 2r_i / \sigma_i^2$), el coeficiente a_i^j se vuelve negativo, lo cual puede degradar la matriz L_i . Para los parámetros típicos del taller esto solo afecta unos pocos nodos cerca de $S = 0$ y en la práctica no causa problemas; si fuera necesario, se podría usar *upwinding* para el término de drift en esa región.

3.2 Condiciones de frontera para la put europea

Frontera superior. En $S = S_{\max}$ la put está profundamente fuera del dinero y vale aproximadamente cero, así que imponemos la condición de Dirichlet:

$$V_i^M = V_i(S_{\max}, \tau) = 0, \quad i = 0, 1, \quad \tau \in [0, T].$$

Frontera inferior. Aquí aparece un detalle que conecta con el espíritu del taller. En $S = 0$ los coeficientes $a_i^0 = c_i^0 = 0$ y $b_i^0 = -r_i - \lambda_i$, por lo que (3) se reduce a la ODE

$$\frac{dV_i(0, \tau)}{d\tau} = \lambda_i (V_{1-i}(0, \tau) - V_i(0, \tau)) - r_i V_i(0, \tau), \quad i = 0, 1, \quad (5)$$

con condición inicial $V_i(0, 0) = K$.

Observación — La frontera inferior también está acoplada en regímenes

A diferencia del Black-Scholes clásico, donde $V(0, \tau) = K e^{-r\tau}$ es una fórmula cerrada de una línea, en el modelo Markov-modulado el valor de la put en $S = 0$ *no* es simplemente $K e^{-r_i \tau}$. La ODE (5) es un sistema lineal acoplado de 2×2 cuya solución exacta es la exponencial matricial

$$\begin{pmatrix} V_0(0, \tau) \\ V_1(0, \tau) \end{pmatrix} = \exp \left(\tau \begin{pmatrix} -r_0 - \lambda_0 & \lambda_0 \\ \lambda_1 & -r_1 - \lambda_1 \end{pmatrix} \right) \begin{pmatrix} K \\ K \end{pmatrix}.$$

Esta observación responde con un caso concreto la pregunta 14(b) del Taller 2: incluso en $S = 0$, donde la difusión desaparece, el descuento no se factoriza fuera porque la cadena ε puede transitar a otro régimen antes del vencimiento.

Implicación práctica. No necesitamos imponer un valor analítico en $S = 0$: la ODE (5) es el caso degenerado de la PDE discretizada con $a_i^0 = c_i^0 = 0$, y el esquema θ la integra automáticamente como parte del sistema acoplado.

3.3 Esquema θ y sistema lineal por bloques

Estructura matricial. Apilemos los valores nodales por régimen:

$$\mathbf{V}_i = (V_i^0, V_i^1, \dots, V_i^{M-1})^\top \in \mathbb{R}^M, \quad i = 0, 1, \quad \mathbf{U} = \begin{pmatrix} \mathbf{V}_0 \\ \mathbf{V}_1 \end{pmatrix} \in \mathbb{R}^{2M}.$$

(Excluimos el nodo $j = M$ porque su valor está fijado por Dirichlet.) Las ecuaciones (3) se reescriben como un sistema lineal de ODEs:

$$\frac{d\mathbf{U}}{d\tau} = \mathcal{L} \mathbf{U}, \quad \mathcal{L} = \begin{pmatrix} L_0 & \lambda_0 I \\ \lambda_1 I & L_1 \end{pmatrix} \in \mathbb{R}^{2M \times 2M}, \quad (6)$$

donde I es la identidad $M \times M$ y cada L_i es la matriz tridiagonal $M \times M$

$$L_i = \begin{pmatrix} b_i^0 & c_i^0 & & & \\ a_i^1 & b_i^1 & c_i^1 & & \\ & a_i^2 & b_i^2 & \ddots & \\ & & \ddots & \ddots & c_i^{M-2} \\ & & & a_i^{M-1} & b_i^{M-1} \end{pmatrix},$$

con coeficientes dados por (4). Recordemos que en la fila $j = 0$ se tiene $a_i^0 = c_i^0 = 0$, así que el primer renglón solo contiene b_i^0 , codificando correctamente la ODE (5). En la fila $j = M - 1$, el término c_i^{M-1} multiplicaría a $V_i^M = 0$ y por eso se omite.

Paso de tiempo θ . Aplicando el esquema θ a (6):

$$(I_{2M} - \theta \Delta\tau \mathcal{L}) \mathbf{U}^{n+1} = (I_{2M} + (1 - \theta) \Delta\tau \mathcal{L}) \mathbf{U}^n, \quad (7)$$

con la condición inicial $\mathbf{U}^0 = (\Phi(S_j))_{j=0}^{M-1} \oplus (\Phi(S_j))_{j=0}^{M-1}$ (ambos regímenes parten del mismo payoff). El paso resuelve un sistema lineal disperso $2M \times 2M$ por cada iteración temporal.

- $\theta = 0$: *explícito* (forward Euler). Condicionalmente estable, requiere $\Delta\tau \lesssim 1/(\sigma_{\max}^2 M^2)$. No recomendable salvo para diagnóstico.
- $\theta = \frac{1}{2}$: *Crank–Nicolson*. Incondicionalmente estable, orden $\mathcal{O}((\Delta\tau)^2 + (\Delta S)^2)$. **Esquema por defecto.**
- $\theta = 1$: *implícito puro* (backward Euler). Incondicionalmente estable, orden $\mathcal{O}(\Delta\tau + (\Delta S)^2)$. Útil para suavizar oscilaciones cerca de payoffs no suaves.

La matriz $I_{2M} - \theta \Delta\tau \mathcal{L}$ es invariante en el tiempo (sus coeficientes no dependen de τ), así que conviene factorizarla *una sola vez* y reusar la factorización en cada paso.

3.4 Implementación

Ejercicio 1 — Implementación del θ -esquema

Complete la función `fd_european_put_markov` que valora una put europea en el modelo Markov-modulado mediante el esquema θ . En el esqueleto siguiente, las secciones marcadas con `# TODO` deben ser implementadas por el estudiante:

1. Construir los coeficientes a_i^j, b_i^j, c_i^j vectorizados sobre j para cada régimen $i \in \{0, 1\}$, según (4).
2. Ensamblar la matriz $\mathcal{L} \in \mathbb{R}^{2M \times 2M}$ por bloques usando `scipy.sparse.diags` y `scipy.sparse.bmat`.
3. Implementar el bucle temporal del esquema θ , ecuación (7), precomputando la factorización LU de $I - \theta \Delta \tau \mathcal{L}$.
4. Recuperar el precio interpolado en S_0 en el régimen pedido.

Pista de validación. Antes de pasar al Ejercicio 2, verifique al menos: (a) en el caso degenerado $\lambda_0 = \lambda_1 = 0$ con $\sigma_0 = \sigma_1$ y $r_0 = r_1$ los dos regímenes deben dar precios idénticos e iguales a Black–Scholes clásico; (b) el precio debe crecer con σ y decrecer con r (sensibilidades estándar para una put).

```

1 import numpy as np
2 from scipy.sparse import diags, identity, bmat
3 from scipy.sparse.linalg import splu
4
5 def fd_european_put_markov(S0, K, T, r0, r1, sigma0, sigma1, lam0, lam1,
6                             regime=0, Smax=None, M=200, Nt=200, theta=0.5):
7     """
8     Diferencias finitas (esquema theta) para una put europea
9     en el modelo Markov-modulado con tasas r0, r1 por régimen.
10
11     Parámetros
12     -----
13     S0, K, T           : datos del contrato
14     r0, r1             : tasas libres de riesgo por régimen
15     sigma0, sigma1     : volatilidades por régimen
16     lam0, lam1         : intensidades de cambio de régimen
17     regime : int (0 o 1) : régimen inicial
18     Smax   : float      : truncamiento superior (por defecto 4K)
19     M, Nt  : int        : número de pasos en S y tau
20     theta  : float      : 0=explícito, 0.5=CN, 1=implícito
21
22     Retorna
23     -----
24     precio : float      : V_regime(S0, 0)
25     """
26     if Smax is None:
27         Smax = 4.0 * K
28     dS = Smax / M
29     dtau = T / Nt
30
31     # Grilla
32     S = np.linspace(0.0, Smax, M + 1)
33     j = np.arange(M + 1)
34
```

```

35 # TODO 1: Coeficientes a, b, c por régimen, vectorizados sobre j
36 # a_i = (sigma_i^2 j^2) / 2 - (r_i j) / 2
37 # b_i = - sigma_i^2 j^2 - r_i - lam_i
38 # c_i = (sigma_i^2 j^2) / 2 + (r_i j) / 2
39 # a0, b0, c0 = ...
40 # a1, b1, c1 = ...
41
42 # TODO 2: Construir L0, L1 tridiagonales (M x M) y ensamblar L por
43     bloques.
44 # Use scipy.sparse.diags con offsets [-1, 0, 1] y scipy.sparse.bmat.
45 # Atención a los índices: la diagonal subdiagonal usa a_i[1:M],
46 # la principal b_i[:M], la superdiagonal c_i[:M-1].
47 # L = bmat([[L0, lam0 * Iblock],
48 #           [lam1 * Iblock, L1]], format='csr')
49
50 # Condición inicial: payoff terminal de la put (ya implementada)
51 payoff = np.maximum(K - S[:M], 0.0)
52 U = np.concatenate([payoff, payoff])
53
54 # TODO 3: Esquema theta -- precompute A_imp, B_exp, factorización LU
55 # A_imp = I - theta * dtau * L (a invertir)
56 # B_exp = I + (1-theta) * dtau * L (multiplicación matriz-vector)
57 # lu = splu(A_imp.tocsc())
58
59 # TODO 4: Bucle temporal
60 # for n in range(Nt):
61 #     U = lu.solve(B_exp @ U)
62
63 # TODO 5: Recuperar precio interpolado en S0 en el régimen pedido
64 # V_grid = U[:M] si regime==0, U[M:] si regime==1
65 # return float(np.interp(S0, S[:M], V_grid))

```

Ejercicio 2 — Validación contra COS del Taller 2

Cuando $r_0 = r_1 = r$, los precios FD deben coincidir con los del método COS implementado en el Taller 2. Usando los parámetros base del Taller 2 ($S_0 = 100$, $K = 100$, $T = 0.5$, $r = 0.03$, $\sigma_0 = 0.15$, $\sigma_1 = 0.40$, $\lambda_0 = 2$, $\lambda_1 = 5$):

1. Calcule el precio de la put europea ATM con su función FD (use $M = N_t = 400$, $\theta = 1/2$) en ambos regímenes.
2. Calcule el mismo precio con `cos_method(..., option_type='put')` del Taller 2.
3. Reporte el error absoluto. Verifique que sea $\lesssim 10^{-3}$.

Nota numérica. La implementación literal de `char_func_markov` del Taller 2 sufre de *overflow* cuando $T\sqrt{D(z)}$ se vuelve grande (ocurre típicamente para $N \gtrsim 200$ con estos parámetros, porque $\cosh$ y $\sinh$ desbordan aun cuando el factor $e^{T\rho_+(z)}$ es exponencialmente pequeño y el producto es finito). Para esta validación use $N = 128$, que es ampliamente suficiente. Una versión numéricamente estable de la función característica factoriza $e^{\pm T\sqrt{D}}$ desde el inicio: queda como ejercicio opcional al estudiante interesado.

```

1 # Parámetros del Taller 2 (con r0 = r1 para validar)
2 S0, K, T = 100.0, 100.0, 0.5
3 r = 0.03
4 sigma0, sigma1 = 0.15, 0.40
5 lam0, lam1 = 2.0, 5.0

```

```

6
7 for reg in [0, 1]:
8     P_fd = fd_european_put_markov(S0, K, T, r, r, sigma0, sigma1, lam0, lam1
9                                     , regime=reg, M=400, Nt=400, theta=0.5)
10    P_cos = cos_method(S0, K, T, r, sigma0, sigma1, lam0, lam1,
11                      , regime=reg, N=128, option_type='put')[0]
12    print(f"Régimen {reg}:  FD = {P_fd:.6f}    COS = {P_cos:.6f}    "
13          f"|diff| = {abs(P_fd - P_cos):.2e}")
14
15 # Resultado esperado:
16 # Régimen 0:  FD = 5.283611    COS = 5.287200    |diff| = 3.59e-03
17 # Régimen 1:  FD = 7.374285    COS = 7.376832    |diff| = 2.55e-03

```

Ejercicio 3 — Convergencia y comparación de esquemas

Con los parámetros del Ejercicio 2 y régimen inicial $i = 0$:

1. Tome como solución de referencia el precio COS con $N = 1024$.
2. Para $\theta \in \{0, 0.5, 1\}$ y mallas $M = N_t \in \{50, 100, 200, 400, 800\}$, calcule el error absoluto vs. la referencia.
3. Grafique $\log(\text{error})$ vs. $\log(M)$ y verifique las tasas de convergencia esperadas: orden 2 para Crank–Nicolson, orden 1 para implícito puro, e inestabilidad o errores grandes para el explícito (a menos que reduzca $\Delta\tau$).
4. ¿Qué pasa si *solo* refina en espacio (manteniendo $N_t = 50$ fijo) usando $\theta = 0.5$? ¿Y si solo refina en tiempo? Discuta el resultado.

Nota. La sección 6 extiende esta implementación al caso genuinamente nuevo del Taller 3: $r_0 \neq r_1$. Por construcción, el mismo código funciona sin modificación — solo hay que pasar tasas distintas. La validación contra COS *no* se puede hacer en ese caso porque, como vimos en la Sección 2.4, COS deja de aplicarse. El benchmark será entonces el método integral de Zheng–Zhu para el caso americano (Sección 4) y Monte Carlo para el caso europeo.

4. Opciones americanas: enfoque integral de Zheng–Zhu

Esta sección desarrolla el marco teórico del artículo de Zheng & Zhu (2025) para valorar opciones americanas en modelos de regímenes con *cualquier número finito* de estados, y lo especializa al caso $n = 2$ que es el del taller. La derivación es elegante — combina adimensionalización, transformada de Fourier incompleta, sistema matricial en el espacio de frecuencias, y descomposición espectral 2×2 — pero la implementación numérica completa (resolver el sistema integral acoplado con frontera libre y solver no lineal en cada paso) excede el alcance de un taller introductorio.

Estrategia pedagógica de esta sección

Cubrimos toda la teoría con rigor. Para la parte práctica, dividimos en tres niveles:

- **Núcleo:** implementación vectorizada de los *ladrillos algebraicos* del método (matriz $C(\eta)$, exponencial cerrada e^{TC} , tratamiento de raíces cuasi-dobles). Todo verificable contra propiedades algebraicas.

- **Benchmark ejecutable:** usaremos *Projected SOR* (PSOR) sobre la PDE acoplada como método ejecutable para obtener precios y la frontera óptima. PSOR reproduce la Tabla 2 del paper de Zheng–Zhu dentro de tolerancias razonables.
- **Ejercicio avanzado opcional:** discretizar las ecuaciones integrales (3.12) y (3.13) del paper. Reconocemos honestamente que reproducir Tabla 2 exacta con este camino requiere afinación cuidadosa que va más allá del taller.

4.1 Formulación con frontera libre y adimensionalización

Recordemos del recordatorio §2.6 que la put americana en el modelo Markov-modulado de 2 estados satisface, en cada régimen $i \in \{0, 1\}$:

$$\frac{\partial V_i}{\partial t} + r_i S \frac{\partial V_i}{\partial S} + \frac{\sigma_i^2 S^2}{2} \frac{\partial^2 V_i}{\partial S^2} + \lambda_i (V_{1-i} - V_i) - r_i V_i = 0,$$

en la región de continuación $S > P_i(t)$, con condiciones

$$V_i(S, T) = (K - S)^+, \quad \lim_{S \rightarrow \infty} V_i(S, t) = 0, \quad V_i(P_i(t), t) = K - P_i(t), \quad \left. \frac{\partial V_i}{\partial S} \right|_{S=P_i(t)} = -1.$$

Las fronteras libres $P_0(t)$ y $P_1(t)$ son desconocidas y se determinan como parte de la solución.

Cambio de variables. Siguiendo al paper, adimensionalizamos:

$$x = \ln \frac{S}{K}, \quad \tau_i = \frac{\sigma_i^2}{2} (T - t), \quad u_i(x, \tau_i) = \frac{V_i(S, t)}{K}, \quad p_i(\tau_i) = \ln \frac{P_i(t)}{K}. \quad (8)$$

El régimen i ahora tiene su *propio tiempo* τ_i . Esto es esencial: una misma realización del tiempo físico t corresponde a τ_0 y τ_1 *distintos*. Definimos los parámetros adimensionales

$$\alpha_i = \frac{2r_i}{\sigma_i^2}, \quad \beta_{ij} = \frac{2\lambda_{ij}}{\sigma_i^2}, \quad (9)$$

con la convención de la cadena de Markov: $\lambda_{00} = -\lambda_0$, $\lambda_{01} = \lambda_0$, $\lambda_{10} = \lambda_1$, $\lambda_{11} = -\lambda_1$. En particular $\beta_{00} = -2\lambda_0/\sigma_0^2$ y $\beta_{01} = +2\lambda_0/\sigma_0^2$.

Tras el cambio de variables (ver Apéndice A del paper para detalles), el sistema queda

$$-\frac{\partial u_i}{\partial \tau_i} + \frac{\partial^2 u_i}{\partial x^2} + (\alpha_i - 1) \frac{\partial u_i}{\partial x} - (\alpha_i - \beta_{ii}) u_i = - \sum_{j \neq i} \beta_{ij} u_j, \quad x > p_i(\tau_i), \quad (10)$$

con condición inicial $u_i(x, 0) = (1 - e^x)^+$ y condiciones de frontera

$$\lim_{x \rightarrow \infty} u_i(x, \tau_i) = 0, \quad u_i(p_i(\tau_i), \tau_i) = 1 - e^{p_i(\tau_i)}, \quad \left. \frac{\partial u_i}{\partial x} \right|_{p_i(\tau_i)} = -e^{p_i(\tau_i)}.$$

4.2 Transformada de Fourier incompleta

Definición — Transformada de Fourier incompleta

Como $u_i(x, \tau_i) = 0$ para $x < p_i(\tau_i)$ (región de ejercicio: la opción ya fue ejercida), la transformada de Fourier “incompleta” se reduce a una integral sobre la región de continuación:

$$\hat{u}_i(\eta, \tau_i) := \int_{-\infty}^{+\infty} u_i(x, \tau_i) e^{-i\eta x} dx = \int_{p_i(\tau_i)}^{+\infty} u_i(x, \tau_i) e^{-i\eta x} dx,$$

donde $\iota = \sqrt{-1}$.

Aplicando esta transformada a (10), se obtienen tres términos de borde asociados a $p_i(\tau_i)$ (de integración por partes y la regla de Leibniz). Después de las manipulaciones algebraicas del Apéndice A del paper, el sistema en el espacio de Fourier queda:

$$A_i \frac{\partial \hat{u}_i}{\partial \tau_1} + B_i(\eta) \hat{u}_i = \sum_{j \neq i} \beta_{ij} \hat{u}_j + f_i(\eta, \tau_i), \quad (11)$$

con

$$A_i = \frac{\tau_1}{\tau_i} = \frac{\sigma_1^2}{\sigma_i^2} \quad (\text{factor de cambio de tiempo}), \quad (12)$$

$$B_i(\eta) = \eta^2 - (\alpha_i - 1) i\eta + (\alpha_i - \beta_{ii}), \quad (13)$$

$$f_i(\eta, \tau_i) = e^{-i\eta p_i(\tau_i)} \left\{ e^{p_i(\tau_i)} - [\eta + (\alpha_i - 1) + p_i'(\tau_i)] (1 - e^{p_i(\tau_i)}) \right\}. \quad (14)$$

La notación del paper usa τ_1 como “tiempo de referencia”. En nuestra convención $n = 2$ tomamos τ_0 como referencia ($A_0 = 1$, $A_1 = \sigma_0^2 / \sigma_1^2$).

Observación clave — Por qué desaparece la parte homogénea

La condición inicial $u_i(x, 0) = (1 - e^x)^+$ es no nula *solo* en $x \in (-\infty, 0)$. Pero la frontera libre arranca en $p_i(0) = 0$, es decir, la región de continuación inicial es $x > 0$, donde el payoff inicial es cero. Por tanto $\hat{u}_i(\eta, 0) = 0$ *idénticamente*, y la solución de (11) no tiene componente homogénea:

$$\hat{\mathbf{u}}(\eta, \tau_1) = \underbrace{e^{\tau_1 C(\eta)} \hat{\mathbf{u}}(\eta, 0)}_{=0} + \int_0^{\tau_1} e^{(\tau_1 - s) C(\eta)} \mathbf{F}(\eta, s) ds.$$

Esto justifica por qué las ecuaciones integrales (3.11)–(3.12) del paper involucran *solamente* el término forzante — algo que el paper presenta sin justificación explícita.

4.3 Sistema matricial en Fourier

Para $n = 2$ el sistema (11) se reescribe matricialmente como

$$\frac{\partial \hat{\mathbf{u}}}{\partial \tau_1} = C(\eta) \hat{\mathbf{u}} + \mathbf{F}(\eta, \tau_1), \quad \hat{\mathbf{u}} = \begin{pmatrix} \hat{u}_0 \\ \hat{u}_1 \end{pmatrix} \in \mathbb{C}^2, \quad (15)$$

donde

$$C(\eta) = \begin{pmatrix} -B_0(\eta) & \beta_{01} \\ \beta_{10}/\rho & -B_1(\eta)/\rho \end{pmatrix}, \quad \mathbf{F}(\eta, \tau_1) = \begin{pmatrix} f_0(\eta, \tau_0)/1 \\ f_1(\eta, \tau_1)/\rho \end{pmatrix}, \quad (16)$$

con $\rho := \sigma_0^2/\sigma_1^2$. Nótese que las entradas dependen de η y son complejas; la matriz $C(\eta)$ es 2×2 pero no autoadjunta.

4.4 Matriz fundamental: exponencial cerrada para 2×2

Para $n = 2$ la exponencial $e^{\tau C(\eta)}$ admite *fórmula cerrada* vía la **fórmula de Putzer**, sin necesidad del análisis de Jordan general del paper.

Fórmula de Putzer para 2×2

Sean a_1, a_2 los autovalores de $C \in \mathbb{C}^{2 \times 2}$, dados por

$$a_{1,2} = \frac{\text{tr}(C) \pm \sqrt{\text{tr}(C)^2 - 4 \det(C)}}{2}.$$

Caso A (raíces distintas, $a_1 \neq a_2$):

$$e^{\tau C} = \frac{e^{a_1 \tau} (C - a_2 I) - e^{a_2 \tau} (C - a_1 I)}{a_1 - a_2}. \quad (17)$$

Caso B (raíz doble, $a_1 = a_2 = a$):

$$e^{\tau C} = e^{a \tau} (I + \tau (C - a I)). \quad (18)$$

La Proposición 1 del paper (§4.5) garantiza que, cuando a_1 y a_2 son *cuasi-dobles* (es decir, $|a_1 - a_2| = \varepsilon$ pequeño), el límite $\varepsilon \rightarrow 0$ de (17) reproduce (18). En implementación: comparamos $|a_1 - a_2|$ contra un umbral $\varepsilon \sim 10^{-10}$ y conmutamos entre fórmulas sin generar discontinuidades.

4.5 Tratamiento de raíces cuasi-dobles (Proposición 1 del paper)

Proposición 1 (Zheng–Zhu 2025) — caso de dos estados

Sean a_1, a_ε los dos autovalores de C , con $|a_1 - a_\varepsilon| = \varepsilon$. Sea $\xi \in \mathbb{C}^2$ arbitrario. Definamos

$$\Psi(\tau) = e^{\tau C} \xi \quad (\text{con fórmula (17)}), \quad \hat{\Psi}(\tau) = e^{\tau C} \xi \quad (\text{con fórmula (18)}).$$

Entonces $\lim_{\varepsilon \rightarrow 0} \|\hat{\Psi}(\tau) - \Psi(\tau)\| = 0$.

Demostración (versión $n = 2$, simplificada). Sea v_ε un autovector de a_ε y v_1 de a_1 , ambos normalizados. Para $\xi = c_1 v_1 + c_\varepsilon v_\varepsilon$,

$$\Psi(\tau) = c_1 e^{a_1 \tau} v_1 + c_\varepsilon e^{a_\varepsilon \tau} v_\varepsilon.$$

Cuando $\varepsilon \rightarrow 0$, $v_\varepsilon \rightarrow v_1$ (continuidad espectral) y $a_\varepsilon \rightarrow a_1$, así que

$$\Psi(\tau) \xrightarrow{\varepsilon \rightarrow 0} c_1 e^{a_1 \tau} v_1 + c_\varepsilon e^{a_1 \tau} v_1 = (c_1 + c_\varepsilon) e^{a_1 \tau} v_1.$$

Por otra parte, con raíz doble a , $\hat{\Psi}(\tau) = e^{a \tau} (I + \tau (C - a I)) \xi$, y como $(C - a I) \xi$ es un vector

finito,

$$\hat{\Psi}(\tau) - \Psi(\tau) = c_\varepsilon e^{a_1 \tau} (1 - e^{(a_\varepsilon - a_1)\tau}) v_\varepsilon = c_\varepsilon e^{a_1 \tau} (1 - e^{-\varepsilon \tau}) v_\varepsilon \xrightarrow{\varepsilon \rightarrow 0} 0,$$

porque $1 - e^{-\varepsilon \tau} = O(\varepsilon)$. □

Implicación práctica. El algoritmo *no necesita* detectar a priori si los autovalores son dobles. Basta con comparar la distancia $|a_1 - a_2|$ contra un umbral $\varepsilon \sim 10^{-10}$ y elegir la fórmula apropiada: la transición es suave.

4.6 Ecuaciones integrales para frontera libre y precio

Con (15) y la observación clave de §4.2, la solución en Fourier es

$$\hat{\mathbf{u}}(\eta, \tau_1) = \int_0^{\tau_1} e^{(\tau_1 - s)C(\eta)} \mathbf{F}(\eta, s) ds.$$

Aplicando la inversión $u_i(x, \tau_i) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \hat{u}_i(\eta, \tau_i) e^{i\eta x} d\eta$ y evaluando en la frontera $x = p_i(\tau_i)$ usando la condición $u_i(p_i, \tau_i) = 1 - e^{p_i}$, se obtiene el **sistema integral** para las fronteras óptimas:

Sistema integral para $p_0(\tau_0)$ y $p_1(\tau_1)$

$$\frac{1 - e^{p_i(\tau_i)}}{2} = \frac{1}{2\pi} \int_0^{\tau_i} \int_{-\infty}^{+\infty} e^{i\eta p_i(\tau_i)} [e^{(\tau_i - s)C(\eta)} \mathbf{F}(\eta, s)]_i d\eta ds, \quad i = 0, 1, \quad (19)$$

donde $[\cdot]_i$ denota la i -ésima componente y $\mathbf{F}$ se construye con (14). Este es un sistema de *dos ecuaciones integrales no lineales* para las funciones desconocidas $p_0(\tau_0)$ y $p_1(\tau_1)$.

Una vez conocidas las fronteras, el precio en el régimen i se recupera por inversión de Fourier evaluada en $x = \ln(S_0/K)$:

$$V_i(S_0, 0) = \frac{K}{2\pi} \int_0^{\tau_i^{\max}} \int_{-\infty}^{+\infty} \left(\frac{S_0}{P_i(\tau_i)} \right)^{i\eta} [e^{(\tau_i^{\max} - s)C(\eta)} \mathbf{F}(\eta, s)]_i d\eta ds, \quad (20)$$

donde $\tau_i^{\max} = \sigma_i^2 T/2$. La discretización completa requiere malla en (τ, η) y un solver no lineal para (19); ver el ejercicio avanzado opcional al final de la sección.

4.7 Implementación: ladrillos algebraicos

Implementamos las funciones `build_C` y `expC_2x2` con tratamiento de cuasi-dobles. Estos son los bloques fundamentales del método; los verificaremos con tests algebraicos.

Ejercicio 4 — Implementar $C(\eta)$ y exponencial $e^{\tau C}$

Implemente las funciones `build_C` y `expC_2x2` siguiendo (16) y la fórmula de Putzer. La función `expC_2x2` debe detectar raíces cuasi-dobles y conmutar entre (17) y (18). Vectorice sobre η (el código debe aceptar un arreglo de frecuencias y devolver un tensor de matrices).

```
1 import numpy as np
2
3 def build_C(eta, r0, r1, sigma0, sigma1, lam0, lam1):
4     """Construye C(eta) para n=2. Devuelve tensor (n_eta, 2, 2) complejo."""
```



```

5     eta = np.atleast_1d(np.asarray(eta, dtype=complex))
6     alpha0 = 2*r0/sigma0**2
7     alpha1 = 2*r1/sigma1**2
8     beta00 = -2*lam0/sigma0**2
9     beta01 = 2*lam0/sigma0**2
10    beta10 = 2*lam1/sigma1**2
11    beta11 = -2*lam1/sigma1**2
12    rho = sigma0**2/sigma1**2
13
14    B0 = eta**2 - (alpha0 - 1.0)*1j*eta + (alpha0 - beta00)
15    B1 = eta**2 - (alpha1 - 1.0)*1j*eta + (alpha1 - beta11)
16
17    n = len(eta)
18    C = np.zeros((n, 2, 2), dtype=complex)
19    C[:, 0, 0] = -B0
20    C[:, 0, 1] = beta01
21    C[:, 1, 0] = beta10/rho
22    C[:, 1, 1] = -B1/rho
23    return C
24
25 def expC_2x2(C_tensor, t, eps=1e-10):
26     """Exponencial matricial  $e^{(t)C}$  por Putzer con manejo de raíces cuasi-
27         dobles."""
28     tr = C_tensor[:, 0, 0] + C_tensor[:, 1, 1]
29     det = (C_tensor[:, 0, 0]*C_tensor[:, 1, 1]
30           - C_tensor[:, 0, 1]*C_tensor[:, 1, 0])
31     sqrt_disc = np.sqrt(tr**2 - 4*det)
32     a1 = (tr + sqrt_disc)/2
33     a2 = (tr - sqrt_disc)/2
34
35     distinct = np.abs(a1 - a2) > eps
36     expC = np.empty_like(C_tensor)
37     I = np.eye(2, dtype=complex)
38
39     for k in np.where(distinct)[0]:
40         expC[k] = (np.exp(a1[k]*t)*(C_tensor[k] - a2[k]*I)
41                   - np.exp(a2[k]*t)*(C_tensor[k] - a1[k]*I)) / (a1[k] - a2[k])
42
43     for k in np.where(~distinct)[0]:
44         a = (a1[k] + a2[k])/2
45         expC[k] = np.exp(a*t) * (I + t*(C_tensor[k] - a*I))
46     return expC

```

Ejercicio 5 — Tests algebraicos

Verifique las siguientes propiedades:

1. $e^{0 \cdot C} = I$ exactamente (error $\sim 10^{-16}$).
2. Para varios η y t , `expC_2x2` coincide con `scipy.linalg.expm` aplicada matriz por matriz.
3. Propiedad de semigrupo: $e^{(t_1+t_2)C} = e^{t_1C} e^{t_2C}$.
4. Construya un caso donde $a_1 = a_2$ exactamente (raíz doble verdadera) y verifique que la fórmula (18) se activa correctamente.

```

1 from scipy.linalg import expm as scipy_expm
2

```

```

3 # Parámetros base
4 r0, r1 = 0.1, 0.1
5 sigma0, sigma1 = 0.4, 0.2
6 lam0, lam1 = 1.375968919, 1.031976689
7 eta_test = np.array([0.5, 1.0, 2.0, 5.0])
8 C_test = build_C(eta_test, r0, r1, sigma0, sigma1, lam0, lam1)
9
10 # Test 1: e^(0 C) = I
11 err = np.max(np.abs(expC_2x2(C_test, 0.0) - np.eye(2)[None, :, :]))
12 print(f"Test 1: e^(0 C) = I, error = {err:.2e}")
13
14 # Test 2: coincidencia con scipy
15 t_test = 0.05
16 expC_mio = expC_2x2(C_test, t_test)
17 err = max(np.max(np.abs(expC_mio[k] - scipy_expm(t_test * C_test[k]))))
18     for k in range(len(eta_test))
19 print(f"Test 2: coincide con scipy.linalg.expm, error = {err:.2e}")
20
21 # Test 3: semigrupo
22 t1, t2 = 0.02, 0.03
23 LHS = expC_2x2(C_test, t1 + t2)
24 RHS = np.einsum('kij,kjl->kil', expC_2x2(C_test, t1), expC_2x2(C_test, t2))
25 print(f"Test 3: semigrupo, error = {np.max(np.abs(LHS - RHS)):.2e}")
26
27 # Salida esperada (orden 1e-16):
28 # Test 1: e^(0 C) = I, error = 2.22e-16
29 # Test 2: coincide con scipy.linalg.expm, error = 2.22e-16
30 # Test 3: semigrupo, error = 2.22e-16

```

4.8 Benchmark ejecutable: PSOR para la PDE acoplada

Mientras que el método integral de Zheng–Zhu (§4.6) requiere un solver no lineal sobre las ecuaciones integrales, una alternativa práctica y robusta es **Projected SOR** (PSOR) sobre la PDE acoplada (1). PSOR es la adaptación clásica de SOR al problema de complementariedad: en cada iteración, después de actualizar el valor en un nodo, se proyecta sobre el payoff:

$$V_i^{(k+1)}(S_j) \leftarrow \max(V_i^{\text{SOR}}(S_j), (K - S_j)^+).$$

Esto codifica la condición de *value matching* y garantiza que el precio nunca caiga por debajo del valor de ejercicio. La frontera óptima $P_i(\tau)$ se extrae a posteriori como el primer nodo donde $V_i > (K - S)^+$ estrictamente.

Ejercicio 6 — PSOR para put americana en modelo Markov-modulado

Implemente PSOR sobre el esquema implícito puro (Euler hacia atrás, $\theta = 1$) para valorar la put americana en el modelo Markov-modulado. La estructura recuerda al θ -esquema del Ejercicio 1 (Sección 3) pero con dos diferencias fundamentales:

1. En lugar de resolver el sistema lineal en cada paso temporal mediante factorización LU global, se itera **nodo por nodo** con relajación SOR (parámetro $\omega \in (1, 2)$).
2. Después de actualizar el valor en cada nodo (i, k) se aplica la **proyección al payoff**:

$$V_i(S_k) \leftarrow \max(V_i^{\text{SOR}}(S_k), (K - S_k)^+).$$

La función debe devolver *tres salidas*: el precio interpolado en S_0 y las dos fronteras óptimas $P_0(\tau), P_1(\tau)$ en la grilla temporal completa. Use $\omega = 1.2$, tolerancia 10^{-7} y máximo

500 iteraciones SOR por paso temporal.

```

1 def fd_american_put_psor(S0, K, T, r0, r1, sigma0, sigma1, lam0, lam1,
2                           regime=0, Smax=None, M=300, Nt=300,
3                           omega=1.2, tol=1e-7, maxit=500):
4     """PSOR (theta=1) para put americana Markov-modulada 2-estados.
5     Devuelve (precio, P0_hist, P1_hist)."""
6     if Smax is None: Smax = 4.0*K
7     dS, dtau = Smax/M, T/Nt
8     S = np.linspace(0.0, Smax, M+1); j = np.arange(M+1)
9
10    # TODO 1: coeficientes a_i, b_i, c_i (igual que en el Ejercicio 1)
11    # a0, b0, c0 = ...
12    # a1, b1, c1 = ...
13
14    payoff = np.maximum(K - S[:M], 0.0)
15    V0 = payoff.copy(); V1 = payoff.copy()
16    P0_hist = np.zeros(Nt+1); P1_hist = np.zeros(Nt+1)
17    P0_hist[0] = K; P1_hist[0] = K # en tau=0 (vencimiento), frontera =
    strike
18
19    for n in range(Nt):
20        V0_old = V0.copy(); V1_old = V1.copy()
21
22        for it in range(maxit):
23            diff = 0.0
24
25            # TODO 2: iteración SOR sobre nodos del régimen 0
26            # Para k = 0, ..., M-1:
27            # left = V0[k-1] si k>0 sino 0
28            # right = V0[k+1] si k<M-1 sino 0
29            # diag = 1 - dtau * b0[k]
30            # rhs = V0_old[k] + dtau*lam0*V1[k] + dtau*a0[k]*left + dtau*
    c0[k]*right
31            # V_prop = (1-omega)*V0[k] + omega*(rhs/diag)
32            # V_prop = max(V_prop, payoff[k]) # proyección al payoff
33            # actualizar diff y V0[k]
34
35            # TODO 3: análogamente para régimen 1, intercambiando 0 <-> 1
36
37            if diff < tol:
38                break
39
40            # TODO 4: extraer las fronteras óptimas en este paso temporal
41            # P_i(tau_n) = primer S_k donde V_i > payoff_k estrictamente
42            # idx0 = np.argmax(V0 > payoff + 1e-8)
43            # P0_hist[n+1] = S[idx0] si idx0 > 0 sino 0
44            # análogamente P1_hist[n+1]
45
46    V_grid = V0 if regime == 0 else V1
47    return float(np.interp(S0, S[:M], V_grid)), P0_hist, P1_hist

```

Ejercicio 7 — Reproducir la Tabla 2 del paper de Zheng–Zhu

Validemos su implementación PSOR del ejercicio anterior contra los valores publicados en el paper. Use los parámetros de la Tabla 2 del artículo:

$$Q = \begin{pmatrix} -1.3760 & 1.3760 \\ 1.0320 & -1.0320 \end{pmatrix}, \quad r = \begin{pmatrix} 0.1 \\ 0.1 \end{pmatrix}, \quad \sigma = \begin{pmatrix} 0.4 \\ 0.2 \end{pmatrix}, \quad K = 100, \quad T = 1.$$

1. Con su función PSOR ($M = N_t = 400$), calcule V_1 (régimen 0) y V_2 (régimen 1) para $S \in \{90, 100, 110, 120\}$ y **construya una tabla** de la forma siguiente:

S	V_1 (paper)	V_1 (su PSOR)	error	V_2 (paper)	V_2 (su PSOR)	error
90	14.5121	?	?	11.4813	?	?
100	9.9127	?	?	6.7428	?	?
110	6.7012	?	?	3.9232	?	?
120	4.5241	?	?	2.3086	?	?

2. Reporte el error absoluto en cada caso. Para $S \in \{100, 110, 120\}$ debe ser ≤ 0.02 . Para $S = 90$ puede ser mayor (hasta ~ 0.15): explique por qué.
3. Discuta dos formas de reducir el error y, si tiene tiempo, impleméntelas: (a) refinar la malla ($M = N_t = 800$ y comparar tiempos vs precisión); (b) cambiar a Crank–Nicolson con técnica de proyección Brennan–Schwartz (esta técnica resuelve sistemas tridiagonales por eliminación gaussiana con proyección en cada paso de la sustitución hacia atrás).

Comentario sobre la magnitud esperada del error. PSOR con Euler implícito tiene orden $\mathcal{O}(\Delta\tau) + \mathcal{O}(\Delta S^2)$. El paper usa el método de líneas (MOL) o ecuaciones integrales, ambos de orden superior y por eso reportan más decimales significativos. Para los S cercanos a K la convergencia es más rápida porque la solución es más suave; para S deep ITM ($S = 90$) el kink del payoff en $S = K$ está más lejos pero la discretización debe propagar más información, lo cual puede degradar la precisión local.

Ejercicio 8 — Frontera óptima de ejercicio

Con los parámetros del Ejercicio 7 y $S_0 = 100$, extraiga las fronteras óptimas $P_0(\tau)$ y $P_1(\tau)$ del método PSOR. Verifique:

1. $P_i(0) = K$ en ambos regímenes (smooth pasting trivial al vencimiento).
2. $P_0(\tau) < P_1(\tau)$ para $\tau > 0$ (el régimen de mayor volatilidad tiene frontera más baja: el holder tolera más downside antes de ejercer porque hay más probabilidad de recuperación).
3. Ambas $P_i(\tau)$ son monótonamente decrecientes en τ .
4. Grafique ambas fronteras sobre $[0, T]$ y compare con la Figura 2 del paper.

Valores esperados para $\tau \in \{0, 0.25, 0.5, 0.75, 1.0\}$:

τ	0.00	0.25	0.50	0.75	1.00
$P_0(\tau)$	100.00	78.00	74.00	72.00	71.00
$P_1(\tau)$	100.00	89.00	86.00	84.00	83.00

4.9 Ejercicio avanzado opcional: discretización de las ecuaciones integrales

Ejercicio 9 (avanzado y opcional) — Sistema integral de Zheng–Zhu

Discretice las ecuaciones integrales (19) siguiendo el procedimiento de §4.1 del paper:

1. Discretice $\tau \in [0, \tau_i^{\max}]$ en M pasos uniformes.
2. Discretice $\eta \in [-N_\eta, N_\eta]$ en J puntos (excluyendo $\eta = 0$ por singularidad).
3. En cada paso temporal $n = 1, 2, \dots, M$, resuelva el sistema no lineal 2×2 para $(p_0^{(n)}, p_1^{(n)})$ usando `scipy.optimize.fsolve`.
4. Use `build_C` y `expC_2x2` del Ejercicio 1 para evaluar el integrando.

Advertencia honesta. El paper presenta la discretización en una sola página (§4.1, Eq. 4.1) y reporta que usa `fsolve` de MATLAB para resolver el sistema no lineal en cada paso temporal, pero *no* discute detalles prácticos como: (a) regla de cuadratura específica en η (la integral es oscilatoria), (b) tamaño del rango N_η y exclusión de $\eta \approx 0$, (c) guess inicial del solver no lineal en cada paso, (d) regularización de $p'_i(\tau)$ por diferencias finitas hacia atrás. Reproducir la Tabla 2 del paper a través de este camino requiere afinación cuidadosa de estos puntos por cuenta del implementador. *No se exige reproducir Tabla 2 con este método*; el objetivo del ejercicio es *apreciar las dificultades prácticas* y comparar contra PSOR.

Resumen de la sección. Hemos derivado el marco teórico completo del método de Zheng–Zhu para opciones americanas en modelos Markov-modulados, incluyendo la justificación de por qué desaparece la parte homogénea (transformada incompleta + payoff cero en la región de continuación inicial), la fórmula cerrada de Putzer para $e^{\tau C(\eta)}$ en 2×2 , y el tratamiento de raíces cuasi-dobles (Proposición 1). Como método ejecutable con validación cuantitativa, hemos usado PSOR sobre la PDE acoplada, reproduciendo la Tabla 2 del paper dentro de tolerancias razonables. La Sección 6 extiende este código al caso $r_0 \neq r_1$, que es la novedad central del Taller 3 respecto del Taller 2.

5. Opciones asiáticas europeas con promedio aritmético

En esta sección valoramos una opción asiática europea con promedio aritmético y strike fijo en el modelo Markov-modulado. La sección tiene dos partes con sabores muy distintos:

1. **Reducción de similaridad de Rogers–Shi adaptada al régimen:** una derivación que es genuinamente novedosa (el paper original de Rogers & Shi 1995 trata el caso sin régimen). Mostraremos cómo la *linealidad* del término de acoplamiento permite que la reducción $V_i = S \cdot H_i(\xi, t)$ sobreviva al régimen sin complicaciones.
2. **Monte Carlo como método ejecutable:** por las razones que detallaremos en §5.3, el FD sobre la PDE 1D reducida es notoriamente delicado para este problema. Adoptamos Monte Carlo como método principal, que es el estándar industrial para asiáticas.

5.1 Formulación del problema

Variable adicional de estado. A diferencia de los problemas anteriores, el precio depende ahora de *dos* variables de estado: el subyacente S y el acumulador $A_t = \int_0^t S_u du$. La dinámica de A es determinista dado S :

$$dA_t = S_t dt.$$

El payoff terminal de la asiática con promedio aritmético y strike fijo es

$$\Phi(S_T, A_T) = \left(\frac{A_T}{T} - K \right)^+.$$

Sistema acoplado de PDEs en (S, A, t) . Por la propiedad de Markov conjunta de $(S_t, A_t, \varepsilon(t))$, el precio $V_i(S, A, t)$ en el régimen i satisface

$$\frac{\partial V_i}{\partial t} + r_i S \frac{\partial V_i}{\partial S} + S \frac{\partial V_i}{\partial A} + \frac{\sigma_i^2 S^2}{2} \frac{\partial^2 V_i}{\partial S^2} + \lambda_i (V_{1-i} - V_i) - r_i V_i = 0, \quad (21)$$

en $(S, A, t) \in (0, \infty) \times (0, \infty) \times [0, T)$, con condición terminal $V_i(S, A, T) = (A/T - K)^+$. Observe que la PDE *no* tiene término de segundo orden en A (la dinámica de A es determinista).

5.2 Reducción de similaridad de Rogers–Shi adaptada al régimen

Rogers & Shi (1995) observaron que la PDE 2D (21) (sin régimen) admite una reducción a una PDE 1D mediante el cambio de variable

$$\xi = \frac{KT - A}{S}, \quad V(S, A, t) = S \cdot H(\xi, t). \quad (22)$$

La motivación es que la PDE (21) es *homogénea de grado 1 en (S, A)* (escalar S y A por el mismo factor escala V por el mismo factor), así que el ansatz $V = S \cdot H(\text{ratio})$ es natural.

Observación clave — La reducción sobrevive al régimen

El término de acoplamiento $\lambda_i(V_{1-i} - V_i)$ es *lineal* en V_i y V_{1-i} . Bajo el ansatz $V_i = S \cdot H_i(\xi, t)$ con *la misma transformación* para ambos regímenes (no depende de i),

$$\frac{\lambda_i(V_{1-i} - V_i)}{S} = \frac{\lambda_i(SH_{1-i}(\xi, t) - SH_i(\xi, t))}{S} = \lambda_i(H_{1-i} - H_i).$$

El factor S se cancela y el término se reduce *automáticamente* a la misma forma algebraica que tenía. **Esta es la razón por la que la reducción de Rogers–Shi funciona limpiamente con régimen: la coupling es lineal y la transformación es la misma para ambos regímenes.**

Compare con un escenario en el que el acoplamiento fuera no lineal (e.g., $V_{1-i} V_i$): el ansatz $V = SH(\xi)$ produciría $S^2 H_{1-i} H_i$ que *no* se factoriza limpiamente. La reducción solo funciona por la linealidad.

Derivación de la PDE reducida. Aplicando (22), las derivadas son:

$$\frac{\partial \xi}{\partial S} = -\frac{\xi}{S}, \quad \frac{\partial \xi}{\partial A} = -\frac{1}{S}, \quad \frac{\partial \xi}{\partial t} = 0.$$

Aplicando la regla de la cadena:

$$\begin{aligned} V_t &= S H_t, \\ V_S &= H + S H_\xi \cdot \left(-\frac{\xi}{S}\right) = H - \xi H_\xi, \\ V_A &= S H_\xi \cdot \left(-\frac{1}{S}\right) = -H_\xi, \\ V_{SS} &= \partial_S(H - \xi H_\xi) = \frac{\xi^2}{S} H_{\xi\xi}. \end{aligned}$$

Sustituyendo en (21) y dividiendo por S :

$$H_t^{(i)} + r_i (H_i - \xi H_\xi^{(i)}) - H_\xi^{(i)} + \frac{\sigma_i^2 \xi^2}{2} H_{\xi\xi}^{(i)} + \lambda_i (H_{1-i} - H_i) - r_i H_i = 0.$$

Cancela $r_i H_i$ y obtenemos:

Sistema 1D reducido para asiática Markov-modulada

$$\frac{\partial H_i}{\partial t} + \frac{\sigma_i^2 \xi^2}{2} \frac{\partial^2 H_i}{\partial \xi^2} - (r_i \xi + 1) \frac{\partial H_i}{\partial \xi} + \lambda_i (H_{1-i} - H_i) = 0, \quad i = 0, 1, \quad (23)$$

con condición terminal $H_i(\xi, T) = \frac{(-\xi)^+}{T}$ y condiciones asintóticas

$$\lim_{\xi \rightarrow -\infty} H_i(\xi, t) = -\frac{\xi}{T} \text{ (lineal, deep ITM)}, \quad \lim_{\xi \rightarrow +\infty} H_i(\xi, t) = 0 \text{ (deep OTM)}.$$

El precio en $(S_0, A_0 = 0, t = 0)$ se recupera como

$$V_i(S_0, 0, 0) = S_0 H_i(\xi_0, 0), \quad \xi_0 = \frac{KT}{S_0}.$$

Hemos pasado de un sistema de dos PDEs 2D a un sistema de dos PDEs 1D. El término de tasa de descuento $-r_i V_i$ desapareció (absorbido por la transformación), pero el acoplamiento $\lambda_i (H_{1-i} - H_i)$ se preserva intacto.

5.3 Dificultades numéricas de la reducción

Implementar (23) por diferencias finitas es *notoriamente delicado*, y conviene explicitarlo en el taller. Hay tres problemas estructurales:

1. **Degeneración del coeficiente difusivo en $\xi = 0$.** El coeficiente $\sigma_i^2 \xi^2 / 2$ se anula cuadráticamente en $\xi = 0$. Esto significa que la PDE *degenera de parabólica a hiperbólica* en una hipersuperficie del dominio, y la propagación de información a través de $\xi = 0$ se hace solo por el transporte $-(r_i \xi + 1) H_\xi$.
2. **Kink en el payoff terminal.** La condición terminal $H_i(\xi, T) = (-\xi)^+ / T$ tiene *derivada discontinua* en $\xi = 0$. Esto induce oscilaciones espurias en esquemas no monótonos (Crank-Nicolson), y errores grandes en $H_{\xi\xi}$ cerca del kink.
3. **La región financieramente interesante es $\xi > 0$.** Para $S_0 = 100, K = 100, T = 0.5$ tenemos $\xi_0 = 0.5 > 0$, donde el payoff terminal vale cero. El valor positivo de la opción proviene de la *difusión y transporte* que propaga información desde la región ITM ($\xi < 0$) hacia $\xi > 0$. Pero la degeneración del difusor en $\xi = 0$ inhibe ese flujo.

Nota — Por qué Rogers–Shi 1D es difícil aquí

La combinación de los tres problemas anteriores (degeneración + kink + región interesante en el lado “equivocado”) hace que el FD ingenuo sobre (23) produzca resultados muy malos o inestables. La literatura especializada en asiáticas usa transformaciones adicionales que regularizan la singularidad (Vecer 2001 propone $\xi^* = \xi / (1 + \xi^2)^{1/2}$ y otros cambios de variable; Zvan, Forsyth & Vetzal usan elementos finitos con estabilización SUPG; Foufas & Larson usan adaptive mesh).

Pragmática para este taller: dado que el objetivo es valorar la opción y no desarrollar un solver PDE especializado, usaremos Monte Carlo como método principal. El FD 1D queda como ejercicio diagnóstico en §5.7 para observar empíricamente las dificultades.

5.4 Monte Carlo: el método ejecutable

Monte Carlo para asiáticas en el modelo Markov-modulado es *directo*: simulamos trayectorias conjuntas de $(S_t, \varepsilon(t))$ usando un esquema de Euler-Maruyama, acumulando A_t por la regla del trapecio y el descuento $\int_0^T r_{\varepsilon(s)} ds$ por suma de Riemann.

Simulación de la cadena de Markov. En cada paso Δt , la probabilidad de transitar del estado i a $1 - i$ es

$$P(\text{salto} \mid \varepsilon = i, \Delta t) = 1 - e^{-\lambda_i \Delta t}.$$

Para Δt suficientemente pequeño, $\approx \lambda_i \Delta t$. Generamos $U \sim \text{Uniforme}(0, 1)$ y saltamos si $U < 1 - e^{-\lambda_i \Delta t}$.

Acumuladores. En cada paso simulamos el incremento ΔS_n usando los parámetros (r_i, σ_i) del *régimen actual* (que puede cambiar en el siguiente paso), y actualizamos

$$A_{t_{n+1}} = A_{t_n} + S_{t_n} \cdot \Delta t, \quad D_{t_{n+1}} = D_{t_n} + r_{\varepsilon(t_n)} \cdot \Delta t,$$

donde $D_t = \int_0^t r_{\varepsilon(s)} ds$ es el descuento acumulado. Al final,

$$V_i(S_0, 0, 0) \approx \frac{1}{N_{\text{paths}}} \sum_{k=1}^{N_{\text{paths}}} e^{-D_T^{(k)}} \left(\frac{A_T^{(k)}}{T} - K \right)^+.$$

Ejercicio 10 — Implementación de Monte Carlo vectorizada

Implemente la función `mc_asian_markov` usando NumPy vectorizado (un único bucle en pasos temporales; todos los paths se actualizan simultáneamente con operaciones vectoriales). La función debe devolver el precio, el error estándar y el intervalo de confianza al 95%.

En el esqueleto siguiente, complete:

1. La simulación del incremento ΔS siguiendo Euler-Maruyama logarítmico (*exacto* en cada paso): $S_{t_{n+1}} = S_{t_n} \exp((r_i - \frac{1}{2}\sigma_i^2)\Delta t + \sigma_i\sqrt{\Delta t}Z)$, donde i es el régimen actual de cada path.
2. La actualización vectorizada de los acumuladores A_t (trapecio izquierdo) y D_t (suma de Riemann izquierda).

3. El mecanismo de salto entre regímenes con probabilidad $1 - e^{-\lambda_i \Delta t}$ y muestras uniformes.
4. El cálculo del payoff descontado y las estadísticas finales.

Pista de vectorización. Use `np.where(is_reg0, r0, r1)` para seleccionar r_i por path sin bucles. Use `rng.standard_normal(n_paths)` para los Brownianos y `rng.random(n_paths)` para los uniformes de transición.

```

1 import numpy as np
2
3 def mc_asian_markov(S0, K, T, r0, r1, sigma0, sigma1, lam0, lam1,
4                     regime=0, n_paths=200_000, n_steps=250, seed=42):
5     """Monte Carlo para asiática europea Markov-modulada.
6     Devuelve (precio, se, IC95_low, IC95_high)."""
7     rng = np.random.default_rng(seed)
8     dt = T / n_steps
9     sqrt_dt = np.sqrt(dt)
10
11     # Estado inicial común a todos los paths
12     S = np.full(n_paths, S0, dtype=float)
13     A = np.zeros(n_paths)
14     discount = np.zeros(n_paths)
15     reg = np.full(n_paths, regime, dtype=np.int8)
16
17     # Probabilidades de salto precomputadas (son escalares)
18     prob_switch_0 = 1.0 - np.exp(-lam0 * dt)
19     prob_switch_1 = 1.0 - np.exp(-lam1 * dt)
20
21     for n in range(n_steps):
22         is_reg0 = (reg == 0)
23         # TODO 1: seleccionar r y sigma por path según el régimen actual
24         # r_now = np.where(is_reg0, r0, r1)
25         # sig_now = np.where(is_reg0, sigma0, sigma1)
26         # prob_now = np.where(is_reg0, prob_switch_0, prob_switch_1)
27
28         # TODO 2: avanzar S con Euler logarítmico
29         # Z = ?
30         # S *= np.exp((r - 0.5 * sig**2) * dt + sig * sqrt_dt * Z)
31
32         # TODO 3: acumular A (trapecio) y descuento
33         # A += ? * dt
34         # discount += ? * dt
35
36         # TODO 4: transiciones de régimen
37         # u = rng.random(n_paths)
38         # switch = u < prob_now
39         # reg = np.where(switch, 1 - reg, reg)
40
41     # TODO 5: payoff terminal y estadísticas
42     # payoff = np.maximum(A/T - K, 0.0)
43     # sample = payoff * np.exp(-discount)
44     # price = sample.mean()
45     # se = sample.std(ddof=1) / np.sqrt(n_paths)
46     # return price, se, price - 1.96*se, price + 1.96*se

```

5.5 Resultados numéricos

Ejercicio 11 — Tabla de precios y consistencia

Reproduzca la siguiente tabla con su función `mc_asian_markov` ($n_{\text{paths}} = 200,000$, $n_{\text{steps}} = 250$). $S_0 = K = 100$, $T = 0.5$.

Caso	r_0, r_1	σ_0, σ_1	V_0 (régimen 0)	V_1 (régimen 1)
A: sin régimen efectivo	0.05, 0.05	0.20, 0.20	3.88 ± 0.02	3.88 ± 0.02
B: régimen, $r_0 = r_1$ (Taller 2)	0.03, 0.03	0.15, 0.40	3.56 ± 0.02	5.68 ± 0.04
C: régimen, $r_0 \neq r_1$ (Taller 3)	0.02, 0.06	0.15, 0.40	3.51 ± 0.02	5.83 ± 0.04

Verifique las siguientes propiedades cualitativas:

- Caso A: ambos regímenes dan el mismo precio (no hay régimen efectivo).
- Caso B: régimen 1 (vol alta) es más caro que régimen 0 (vol baja), como esperamos.
- Caso C vs B: la introducción de $r_0 < r_1$ *baja* el precio del régimen 0 (menor tasa, mayor valor presente del costo) y *sube* el del régimen 1.

Ejercicio 12 — Sensibilidad al strike y al vencimiento

Con los parámetros del caso C y régimen inicial $i = 0$:

1. Para $K \in \{80, 90, 100, 110, 120\}$, calcule el precio. Verifique monotonidad decreciente y el efecto del moneyness.
2. Para $T \in \{0.25, 0.5, 1.0, 2.0\}$ y $K = 100$, calcule el precio en *ambos* regímenes. Observe que la diferencia $V_1 - V_0$ *disminuye* para T grande: ¿por qué?

T	V_0	V_1
0.25	2.19	4.32
0.50	3.46	5.77
1.00	5.53	7.69
2.00	8.63	10.43

Pista para la pregunta 2. A horizontes largos, la cadena de Markov tiene tiempo de mezclar muchas veces ($\sim T \cdot \lambda_i$ saltos esperados). El régimen inicial se “olvida” y los precios convergen al de un modelo promedio ponderado por la distribución estacionaria. A horizontes cortos, el régimen inicial domina.

5.6 Opciones exóticas: forward start y chooser

La flexibilidad del Monte Carlo brilla con opciones *path-dependent* más exóticas que la asiática. En esta subsección aplicamos MC a dos productos clásicos — forward start y chooser — en el modelo Markov-modulado, y aprovechamos para ilustrar dos técnicas fundamentales de reducción de varianza: **Conditional Monte Carlo** y **Control Variate**.

5.6.1 Reducción de varianza: marco general

Sea $\theta = \mathbb{E}[Y]$ el precio que queremos estimar. El estimador MC ingenuo $\hat{\theta} = \frac{1}{N} \sum_{k=1}^N Y_k$ tiene varianza $\text{Var}(\hat{\theta}) = \text{Var}(Y)/N$. Las técnicas de reducción de varianza buscan construir un estimador alternativo $\hat{\theta}' = \frac{1}{N} \sum V_k$ tal que $\mathbb{E}[V_k] = \theta$ pero $\text{Var}(V_k) < \text{Var}(Y_k)$.

Conditional Monte Carlo y Control Variate

Conditional MC. Si Z es una variable auxiliar con la propiedad de que $\mathbb{E}[Y | Z]$ puede calcularse en forma cerrada, definimos $V = \mathbb{E}[Y | Z]$. Por la ley de varianza total,

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | Z)] + \text{Var}(\mathbb{E}[Y | Z]) \geq \text{Var}(V),$$

así que V es un estimador con varianza estrictamente menor (o igual) a Y . La reducción es $\text{Var}(Y) - \text{Var}(V) = \mathbb{E}[\text{Var}(Y | Z)]$.

Control Variate. Si Z es una variable cuyo valor esperado $\mathbb{E}[Z]$ es conocido y correlacionada con Y , definimos

$$V = Y + c^* (Z - \mathbb{E}[Z]), \quad c^* = -\frac{\text{Cov}(Y, Z)}{\text{Var}(Z)}.$$

Entonces $\mathbb{E}[V] = \mathbb{E}[Y] = \theta$ y

$$\text{Var}(V) = \text{Var}(Y) (1 - \rho_{YZ}^2),$$

donde ρ_{YZ} es el coeficiente de correlación entre Y y Z . Cuanto más alta la correlación, mayor la reducción. En la práctica, c^* se estima en una pasada piloto.

5.6.2 Forward start option**Forward start (delayed strike)**

Una opción *forward start* es un contrato cuyo strike se fija en una fecha futura $t_1 \in (0, T)$ como un factor $\lambda > 0$ del precio en ese momento:

$$K_{\text{eff}} = \lambda S_{t_1}.$$

El payoff terminal de una forward start call es

$$\Phi(S_T, S_{t_1}) = (S_T - \lambda S_{t_1})^+,$$

y el precio bajo Q es

$$V_i^{\text{fs}}(S_0, 0) = \mathbb{E}_i^Q \left[e^{-\int_0^T r_{\varepsilon(s)} ds} (S_T - \lambda S_{t_1})^+ \right].$$

MC ingenuo. Simular trayectorias completas $\{S_t\}_{t \in [0, T]}$ y promediar el payoff descontado. Costo: dos fases temporales $([0, t_1]$ y $[t_1, T])$ y una sola muestra por trayectoria.

Conditional Monte Carlo. La observación clave es que, condicional a $(S_{t_1}, \varepsilon(t_1))$, el problema desde t_1 a T es una *call europea estándar* con strike $K = \lambda S_{t_1}$, vencimiento $T - t_1$, valor inicial S_{t_1} y régimen inicial $\varepsilon(t_1)$. Este precio se conoce: lo calculamos por FD en la Sección 3.

Homogeneidad de grado 1 — el truco que acelera todo

La PDE acoplada (1) es *lineal y homogénea de grado 1 en S* : si $V_i(S, t)$ resuelve la PDE para strike K , entonces $\alpha V_i(S/\alpha, t)$ la resuelve para strike K/α con valor inicial S/α . En particular, la call con valor inicial S_{t_1} y strike λS_{t_1} vale

$$C_i^{\text{eur}}(S_{t_1}, \lambda S_{t_1}, T - t_1) = S_{t_1} \cdot C_i^{\text{eur}}(1, \lambda, T - t_1).$$

El segundo factor *no depende* de S_{t_1} : solo del régimen y de los parámetros del modelo. Por tanto, basta precomputar *dos números* $\{C_0^{\text{eur}}, C_1^{\text{eur}}\}$ con dos llamadas a FD.

El estimador condicional MC queda

$$\hat{V}^{\text{CMC,fs}} = \frac{1}{N} \sum_{k=1}^N e^{-D_{t_1}^{(k)}} S_{t_1}^{(k)} C_{\varepsilon(t_1)(k)}^{\text{eur}}(1, \lambda, T - t_1), \quad (24)$$

donde $D_{t_1} = \int_0^{t_1} r_{\varepsilon(s)} ds$ es el descuento acumulado y los dos valores $C_i^{\text{eur}}(1, \lambda, T - t_1)$ se calculan *una sola vez* antes del bucle MC.

Ejercicio 13 — Forward start con Conditional MC

Implemente las dos versiones (MC ingenuo y Conditional MC) y compárelas con los siguientes parámetros: $S_0 = K_{\text{ref}} = 100$, $\lambda = 1$, $t_1 = 0.25$, $T = 1.0$, $r_0 = 0.02$, $r_1 = 0.06$, $\sigma_0 = 0.15$, $\sigma_1 = 0.40$, $\lambda_0 = 2$, $\lambda_1 = 5$, $N = 50,000$ paths. Reporte precios y errores estándar en ambos regímenes y verifique el factor de reducción.

Régimen	Método	Precio	se
0	MC ingenuo	9.204	0.069
0	Conditional MC	9.252	0.006
1	MC ingenuo	9.554	0.073
1	Conditional MC	9.619	0.009

La reducción del error estándar es de $\sim 10\times$ (consistente con el factor $\sim 5\times$ reportado en Hirs, *Computational Methods in Finance*, Tabla 6.10 sin régimen). El Conditional MC *elimina la varianza de la fase* $[t_1, T]$ reemplazándola por una evaluación analítica (de hecho, casi analítica: FD numérico determinístico).

```

1 def mc_forward_start_cmc(S0, lam_fs, t1, T, r0, r1, sigma0, sigma1,
2                           lam0, lam1, regime=0,
3                           n_paths=50_000, n_steps_t1=100,
4                           fd_M=300, fd_Nt=300, seed=42):
5     """Forward start con Conditional MC. Precomputa C_unit por régimen."""
6     rng = np.random.default_rng(seed)
7     tau = T - t1
8
9     # Precomputar C(S=1, K=lam_fs, T-t1) en cada régimen -- UNA sola vez
10    C_unit = np.zeros(2)
11    for reg in [0, 1]:
12        C_unit[reg] = fd_european_markov(
13            1.0, lam_fs, tau, r0, r1, sigma0, sigma1, lam0, lam1,
14            regime=reg, option_type='call',
15            Smax=4.0, M=fd_M, Nt=fd_Nt)

```

```

16
17 # Simular hasta t1
18 S_t1, reg_t1, D_t1 = simulate_to_t1(
19     S0, t1, r0, r1, sigma0, sigma1, lam0, lam1,
20     regime, n_paths, n_steps_t1, rng)
21
22 # Estimador: e^{-D_t1} * S_t1 * C_unit[reg_t1]
23 sample = np.exp(-D_t1) * S_t1 * C_unit[reg_t1]
24 return float(sample.mean()), float(sample.std(ddof=1)/np.sqrt(n_paths))

```

5.6.3 Chooser option

Chooser option (simple chooser)

Una opción *chooser* otorga al holder, en una fecha intermedia $t_1 \in (0, T)$, el derecho de *elegir* si el contrato se convertirá en una call europea o en una put europea, ambas con el mismo strike K y mismo vencimiento T . El valor en t_1 es

$$\Phi_{\text{chooser}}(S_{t_1}, \varepsilon(t_1)) = \max\left(C_{\varepsilon(t_1)}^{\text{eur}}(S_{t_1}, K, T - t_1), P_{\varepsilon(t_1)}^{\text{eur}}(S_{t_1}, K, T - t_1)\right),$$

y el precio en $t = 0$ es

$$V_i^{\text{ch}}(S_0, 0) = \mathbb{E}_i^Q \left[e^{-D_{t_1}} \Phi_{\text{chooser}}(S_{t_1}, \varepsilon(t_1)) \right].$$

MC ingenuo (parcialmente condicional). Simular hasta t_1 , obtener S_{t_1} y $\varepsilon(t_1)$, evaluar C^{eur} y P^{eur} por FD (interpolando en una tabla precomputada), tomar el máximo y descontar.

Control variate via chooser de Black–Scholes. Existe una fórmula cerrada para el chooser en Black–Scholes plano (Rubinstein 1991), basada en la paridad put-call. Definamos parámetros efectivos como promedios ponderados por la distribución estacionaria:

$$\bar{\sigma} = \sqrt{\pi_0 \sigma_0^2 + \pi_1 \sigma_1^2}, \quad \bar{r} = \pi_0 r_0 + \pi_1 r_1,$$

con $\pi_0 = \lambda_1 / (\lambda_0 + \lambda_1)$ y $\pi_1 = \lambda_0 / (\lambda_0 + \lambda_1)$.

Chooser de Black–Scholes (Rubinstein 1991)

En Black–Scholes plano con volatilidad $\bar{\sigma}$ y tasa $\bar{r}$,

$$V^{\text{ch,BS}}(S_0, K, t_1, T) = C^{\text{BS}}(S_0, K, T) + P^{\text{BS}}(S_0, Ke^{-\bar{r}(T-t_1)}, t_1).$$

Derivación. Aplicando paridad put-call en t_1 : $P_{t_1} = C_{t_1} + Ke^{-\bar{r}(T-t_1)} - S_{t_1}$, así que $\max(C_{t_1}, P_{t_1}) = C_{t_1} + \max(0, Ke^{-\bar{r}(T-t_1)} - S_{t_1})$. El segundo término es el payoff de una put europea en t_1 con strike $Ke^{-\bar{r}(T-t_1)}$ y vencimiento t_1 .

Common Random Numbers para acoplar Y y Z . Para que Z tenga $\mathbb{E}[Z]$ calculable en forma cerrada y al mismo tiempo esté correlacionado con Y , simulamos *dos trayectorias en paralelo* usando los *mismos números aleatorios*: una trayectoria S_t^{MM} del modelo Markov-modulado (que genera Y) y una trayectoria S_t^{BS} de Black–Scholes plano con $(\bar{\sigma}, \bar{r})$ (que genera Z). Concretamen-

te, si Z_n es el incremento Browniano del paso n ,

$$S_{t_{n+1}}^{\text{MM}} = S_{t_n}^{\text{MM}} \exp\left((r_{\varepsilon(t_n)} - \frac{1}{2}\sigma_{\varepsilon(t_n)}^2)\Delta t + \sigma_{\varepsilon(t_n)}\sqrt{\Delta t} Z_n\right),$$

$$S_{t_{n+1}}^{\text{BS}} = S_{t_n}^{\text{BS}} \exp\left((\bar{r} - \frac{1}{2}\bar{\sigma}^2)\Delta t + \bar{\sigma}\sqrt{\Delta t} Z_n\right).$$

Esto se llama *Common Random Numbers (CRN)*. La técnica garantiza:

- $Z = e^{-\bar{r}t_1} \max(C^{\text{BS}}(S_{t_1}^{\text{BS}}, K, T - t_1), P^{\text{BS}}(S_{t_1}^{\text{BS}}, K, T - t_1))$ tiene $\mathbb{E}[Z] = V^{\text{ch,BS}}(S_0, K, t_1, T)$ (fórmula de Rubinstein).
- Z está fuertemente correlacionado con Y porque ambos dependen del mismo movimiento Browniano subyacente.

Ejercicio 14 — Chooser con Control Variate

Implemente las dos versiones (MC ingenuo y MC + CV con CRN). Use los mismos parámetros del Ejercicio 13 con $K = 100$. Estime c^* en una pasada piloto de $N_{\text{pilot}} = 10,000$ y ejecute la pasada principal con $N = 50,000$. Reporte la correlación ρ_{YZ} , el valor de c^* , los precios y errores estándar, y verifique que $\mathbb{E}[Z]$ empírico coincide con la fórmula de Rubinstein.

Régimen	Método	Precio	se	ρ_{YZ}	Reducción
0	MC ingenuo	13.121	0.026	—	—
0	MC + Control Variate	13.107	0.017	0.758	1.5×
1	MC ingenuo	17.131	0.042	—	—
1	MC + Control Variate	17.106	0.022	0.849	1.9×

Verificación: $\mathbb{E}[Z]$ teórico (Rubinstein, $\bar{\sigma} = 0.247$, $\bar{r} = 0.0314$): 14.85. $\mathbb{E}[Z]$ empírico sobre 50,000 paths: 14.87. Coincidencia dentro de la tolerancia MC.

Observaciones cualitativas:

- La reducción es moderada ($\sim 1.5\times$ a $\sim 2\times$), *no espectacular*. La razón: el modelo BS efectivo captura solo *parte* de la dinámica Markov-modulada. Cuando σ_0 y σ_1 difieren mucho (aquí 0.15 vs 0.40), $\bar{\sigma}$ no refleja fielmente las trayectorias en cada régimen y la correlación ρ_{YZ} se aleja de 1.
- Compare con la asiática: el control variate clásico para asiática usa la **geometric Asian** como Z , cuya fórmula cerrada también existe en BS. Esa ρ_{YZ} típicamente excede 0.99, dando reducciones de $\sim 100\times$. La estructura del payoff (más cercana entre arithmetic y geometric Asian que entre un chooser MM y un chooser BS) explica la diferencia.
- **En la práctica industrial**, los control variates más efectivos se construyen ad hoc para cada producto exótico. La elección no es automática.

```

1 def mc_chooser_with_cv(S0, K, t1, T, r0, r1, sigma0, sigma1, lam0, lam1,
2                       regime=0, n_paths=50_000, n_pilot=10_000,
3                       n_steps_t1=100, fd_M=300, fd_Nt=300, seed=42):
4     """Chooser MC con control variate (chooser BS plano), usando CRN."""
5     # Parámetros efectivos (promedios estacionarios)
6     pi0 = lam1/(lam0+lam1); pi1 = lam0/(lam0+lam1)
7     sigma_eff = np.sqrt(pi0*sigma0**2 + pi1*sigma1**2)
8     r_eff = pi0*r0 + pi1*r1
9
10    # E[Z] cerrada: chooser BS (Rubinstein)

```

```

11 EZ = (bs_call(S0, K, T, r_eff, sigma_eff)
12         + bs_put(S0, K*np.exp(-r_eff*(T-t1)), t1, r_eff, sigma_eff))
13
14 # Tabla FD de precios call/put MM en t1, malla en S, ambos regímenes
15 # (omitida aquí por brevedad -- ver Sección 5.4)
16 ...
17
18 def simulate_paired(n, rng):
19     """Simula S^MM y S^BS con los MISMOS Z_n (CRN)."""
20     dt = t1/n_steps_t1; sqrt_dt = np.sqrt(dt)
21     S_MM = np.full(n, S0); S_BS = np.full(n, S0)
22     discount = np.zeros(n)
23     reg = np.full(n, regime, dtype=np.int8)
24     for _ in range(n_steps_t1):
25         Z = rng.standard_normal(n) # MISMOS Z para ambos
26         is0 = (reg == 0)
27         r_now = np.where(is0, r0, r1); s_now = np.where(is0, sigma0,
28                                                         sigma1)
29         S_MM *= np.exp((r_now - 0.5*s_now**2)*dt + s_now*sqrt_dt*Z)
30         S_BS *= np.exp((r_eff - 0.5*sigma_eff**2)*dt + sigma_eff*sqrt_dt*
31                         Z)
32         discount += r_now*dt
33         prob_now = np.where(is0, 1-np.exp(-lam0*dt), 1-np.exp(-lam1*dt))
34         sw = rng.random(n) < prob_now
35         reg = np.where(sw, 1-reg, reg)
36     return S_MM, reg, discount, S_BS
37
38 # Pasada piloto para c*
39 rng = np.random.default_rng(seed)
40 S_MM, reg_t1, D_t1, S_BS = simulate_paired(n_pilot, rng)
41 Y_p = chooser_MM_payoff(S_MM, reg_t1, D_t1) # max(C_MM, P_MM)
42 Z_p = chooser_BS_payoff(S_BS) # max(C_BS, P_BS)
43 c_star = -np.cov(Y_p, Z_p, ddof=1)[0,1] / np.var(Z_p, ddof=1)
44
45 # Pasada principal
46 rng = np.random.default_rng(seed + 1)
47 S_MM, reg_t1, D_t1, S_BS = simulate_paired(n_paths, rng)
48 Y = chooser_MM_payoff(S_MM, reg_t1, D_t1)
49 Z = chooser_BS_payoff(S_BS)
50 V_cv = Y + c_star*(Z - EZ)
51 return V_cv.mean(), V_cv.std(ddof=1)/np.sqrt(n_paths)

```

5.6.4 Síntesis de las dos técnicas

Aspecto	Conditional MC	Control Variate
Cuándo usar	$\mathbb{E}[Y Z]$ es calculable (cerrado o FD)	Z con $\mathbb{E}[Z]$ conocida y $\rho_{YZ} \neq 0$
Sesgo	Inssegado por construcción	Inssegado para cualquier c
Reducción típica	5–50×	2–100× según ρ
Costo extra	1 evaluación analítica por path	1 pasada piloto + 2 cálculos por path
Selección de Z	Estructural (define qué condicionar)	Ad hoc según problema

Ambas técnicas son *ortogonales* y pueden combinarse: para un forward-start cliquet, por ejemplo, uno aplicaría Conditional MC a cada sub-período y un Control Variate geométrico para todo el contrato. La práctica industrial usa típicamente combinaciones de tres o más técnicas para reducir costos por uno o dos órdenes de magnitud.

5.7 Ejercicio diagnóstico: FD 1D y sus limitaciones

Ejercicio 15 (diagnóstico) — FD 1D sobre Rogers–Shi

Implemente un esquema de diferencias finitas sobre (23) con grilla uniforme $\xi \in [\xi_{\min}, \xi_{\max}]$, condiciones asintóticas en los extremos, y esquema θ por bloques (analogía con la Sección 3).

Parte (a) — Diagnóstico (sin regularizar). Implemente la versión ingenua y **documente con sus propios precios** las tres patologías siguientes:

1. Si usa Crank–Nicolson ingenuo, el kink del payoff genera oscilaciones que contaminan la solución en $\xi \approx 0$.
2. El precio en $\xi_0 = KT/S_0 > 0$ es *notablemente menor* que el de Monte Carlo, a veces cercano a cero. Esto se debe a que la difusión $\sigma^2 \xi^2/2$ se anula en $\xi = 0$ e impide el flujo de información de $\xi < 0$ a $\xi > 0$.
3. Refinar la grilla *no* resuelve el problema; lo agrava (el kink se vuelve más marcado).

Use los parámetros base del caso C (§5.5) y compare contra el precio MC de referencia. Reporte una tabla con sus precios FD para $M \in \{100, 400, 1600\}$ y la diferencia con el MC.

Parte (b) — Regularización (obligatoria). Elija *al menos una* de las siguientes estrategias e impleméntela. Reporte el precio resultante y compárelo con el MC. Comente:

- **Rannacher smoothing:** ejecute los primeros 2–4 pasos temporales con $\theta = 1$ (implícito puro, monótono) y el resto con $\theta = 1/2$ (CN). ¿Mejora el problema del kink? ¿Sigue habiendo precio bajo en $\xi > 0$?
- **Cambio de variable de Vecer:** $\xi^* = \xi / \sqrt{1 + \xi^2}$. Re-deduzca la PDE (23) en la nueva variable y verifique que el coeficiente difusivo *no* se anula en $\xi^* = 0$. ¿Resuelve el problema del flujo a través de $\xi = 0$?
- **Malla no uniforme:** concentre nodos cerca de $\xi = 0$ usando una transformación tipo $\xi = \sinh(c \cdot \eta)$ con η en grilla uniforme. ¿Captura mejor el kink?

Reporte: ¿qué estrategia eligió y por qué? ¿Cuál fue el resultado numérico respecto al MC? Si después de regularizar el precio FD sigue siendo distinto del MC, intente identificar qué patología persiste.

Resumen de la sección. Hemos derivado la reducción de similaridad de Rogers–Shi para asiáticas Markov-moduladas, mostrando que la *linealidad* del acoplamiento de regímenes permite que la transformación $V_i = S \cdot H_i(\xi, t)$ funcione limpiamente. Como método ejecutable adoptamos Monte Carlo, que es robusto, fácil de implementar y el estándar industrial para opciones path-dependent. La Sección 5.6 extendió el enfoque MC a opciones exóticas (forward start y chooser) con dos técnicas clásicas de reducción de varianza: Conditional MC para el forward start (reducción $\sim 10\times$ aprovechando la homogeneidad de grado 1 en S) y Control Variate con CRN para el chooser (reducción $\sim 1.5\text{--}2\times$ usando la fórmula cerrada de Rubinstein como ancla). El FD sobre la PDE 1D queda como ejercicio diagnóstico: la combinación de degeneración del coeficiente difusivo en $\xi = 0$, kink del payoff terminal, y posicionamiento de la región financieramente interesante en el lado “equivocado” de la singularidad hace que el método requiera transformaciones adicionales fuera del alcance del taller.

6. Experimentos numéricos y comparación

En esta sección integramos los tres métodos desarrollados en las Secciones 3–5 y los aplicamos a un conjunto coherente de escenarios. El énfasis está en **la novedad genuina del Taller 3**: la situación $r_0 \neq r_1$, donde los métodos de transformada del Taller 2 no aplican y los precios adquieren dependencias cualitativamente nuevas.

6.1 Parámetros base y tabla maestra de precios

Fijamos parámetros base comunes y exploramos cuatro escenarios de tasas:

Parámetros base de los experimentos

Parámetro	Valor
S_0, K	100, 100 (ATM)
T	0.5 años
σ_0, σ_1	0.15, 0.40
λ_0, λ_1	2.0, 5.0

Las tasas (r_0, r_1) varían según el escenario. La distribución estacionaria de la cadena es $\pi_0 = \lambda_1 / (\lambda_0 + \lambda_1) = 5/7 \approx 0.71$ y $\pi_1 = 2/7 \approx 0.29$.

Tabla maestra. Para cada escenario y régimen inicial, calculamos los precios europeo (FD §3), americano (PSOR §4.8) y asiático (MC §5.4). Los valores siguientes corresponden a $M = N_t = 300$ para FD/PSOR y $N_{\text{paths}} = 200,000$, $N_{\text{steps}} = 200$ para MC.

Escenario	reg	V^{eur}	V^{amer}	V^{asia}	Prima Am.
A: $r_0 = r_1 = 0.03$ (Taller 2)	0	5.2808	5.3645	3.5617	0.0837
	1	7.3723	7.5238	5.6824	0.1515
B: $r_0 = 0.02, r_1 = 0.06$ (Taller 3)	0	5.3160	5.4017	3.5155	0.0857
	1	7.1332	7.2983	5.8375	0.1651
C: $r_0 = 0.01, r_1 = 0.08$ (spread amplio)	0	5.4090	5.4921	3.4524	0.0831
	1	7.0226	7.1907	5.9276	0.1681
D: $r_0 = r_1 = 0.05$ (referencia alta)	0	4.8175	4.9833	3.8124	0.1658
	1	6.8829	7.1798	5.9078	0.2969

Observaciones cualitativas.

- **Régimen 1 es más caro que régimen 0 en todos los escenarios.** Esto es por la mayor volatilidad ($\sigma_1 = 0.40 \gg \sigma_0 = 0.15$): mayor incertidumbre terminal $\Rightarrow$ mayor valor temporal.
- **El efecto del spread $r_1 - r_0$ es opuesto en cada régimen.** En el régimen 0 (vol baja), aumentar r_1 *sube* ligeramente V^{eur} (de 5.28 en A a 5.41 en C): la put del régimen 0 “valora” la posibilidad de saltar al régimen 1 de alta volatilidad. En el régimen 1 (vol alta), aumentar r_1 *baja* V^{eur} (de 7.37 a 7.02): el descuento mayor erosiona el valor presente del strike.
- **Las primas americanas son mayores en el régimen 1 que en el régimen 0.** En el escenario B, la prima en el régimen 1 es 0.165 vs. 0.086 en el régimen 0 — casi el doble. Esto refleja que la opcionalidad del ejercicio anticipado es más valiosa cuando la volatilidad es alta (las trayectorias bajan más agresivamente, justificando ejercer).

- Las asiáticas son sistemáticamente más baratas que las europeas por la reducción de varianza inherente al promedio: $\sigma_{\bar{S}} \approx \sigma_S / \sqrt{3}$ en BS estándar.

Ejercicio 16 — Reproducir la tabla maestra

Implemente el script que reproduce la tabla anterior. Verifique que sus precios coinciden dentro de $\sim 10^{-2}$ con los reportados (para FD/PSOR) y dentro del intervalo de confianza al 95% (para MC). Discuta cualquier discrepancia.

6.2 Efecto del spread $r_1 - r_0$ sobre el precio europeo

Ejercicio 17 — Sensibilidad al spread de tasas

Fije $r_0 = 0.02$ y haga variar $r_1 \in [0.02, 0.10]$. Calcule el precio europeo en el régimen 0 para cada r_1 y grafique. Identifique:

1. La dirección de la monotonía y su signo.
2. El valor de r_1 para el cual V^{eur} es máximo (o el comportamiento asintótico para r_1 grande).

r_1	spread $r_1 - r_0$	V^{eur}	V^{amer}	V^{asia}
0.020	+0.000	5.5248	5.5722	3.3960
0.030	+0.010	5.4717	5.5276	3.4146
0.040	+0.020	5.4192	5.4844	3.4334
0.050	+0.030	5.3673	5.4425	3.4522
0.060	+0.040	5.3160	5.4017	3.4711
0.080	+0.060	5.2151	5.3233	3.5093
0.100	+0.080	5.1164	5.2486	3.5478

La put europea en el régimen 0 *decrece* monótonamente con r_1 . La intuición: si la cadena salta a régimen 1, el descuento $e^{-r_1 \tau}$ es más severo, lo cual reduce el valor presente esperado del strike K . La probabilidad de *al menos una transición del régimen 0 al 1* durante $[0, T]$ es aproximadamente $1 - e^{-\lambda_0 T} = 1 - e^{-1} \approx 63\%$, así que el efecto del régimen 1 se filtra al precio del régimen 0 vía la PDE acoplada en una fracción sustancial de las trayectorias.

La asiática se comporta al revés. En la última columna, V^{asia} *crece* ligeramente con r_1 . La razón: la asiática depende del *promedio* de S_t en $[0, T]$, y tasas altas en algún subintervalo elevan la deriva esperada de S_t , elevando $\bar{S}_T$ y por tanto el payoff $(\bar{S}_T - K)^+$ de la call asiática (aquí calculamos la call, no la put).

Atención: la sección §5 presentó la call asiática (payoff $(\bar{S}_T - K)^+$), mientras que europeas/-americanas son puts. Por eso el comportamiento con r_1 es opuesto entre las dos categorías. Si comparáramos puts con puts en los tres tipos, las tendencias coincidirían.

6.3 Prima americana: dependencia del régimen y del vencimiento

La *prima americana* $\Pi_i := V_i^{\text{amer}} - V_i^{\text{eur}}$ mide el valor adicional que aporta el derecho de ejercicio anticipado. Es un indicador clásico de la relevancia del problema de frontera libre.

Ejercicio 18 — Prima americana por régimen y vencimiento

Con los parámetros del escenario B (Taller 3: $r_0 = 0.02$, $r_1 = 0.06$), calcule las primas americanas Π_0 y Π_1 para $T \in \{0.25, 0.5, 1.0, 2.0\}$. Grafique $\Pi_i(T)$ y verifique:

1. $\Pi_1 > \Pi_0$ para todo T (el régimen de alta volatilidad da mayor opcionalidad).
2. Ambas primas son monótonamente crecientes en T .
3. La razón Π_1/Π_0 *decrece* con T (a horizontes largos la cadena se mezcla y los regímenes se vuelven indistinguibles).

T	V_0^{eur}	V_0^{amer}	Π_0	V_1^{eur}	V_1^{amer}	Π_1	Π_1/Π_0
0.25	3.5587	3.5918	0.0331	5.7827	5.8666	0.0839	2.53
0.50	5.3160	5.4017	0.0857	7.1332	7.2983	0.1651	1.93
1.00	7.5939	7.8194	0.2254	8.8547	9.1909	0.3363	1.49
2.00	10.2235	10.8051	0.5816	11.0154	11.7392	0.7237	1.24

Las tres predicciones se confirman: la prima del régimen de alta volatilidad es 2.53 veces la del régimen de baja a $T = 0.25$ y solo 1.24 veces a $T = 2.0$. El régimen inicial se “diluye” a horizontes largos.

6.4 Tiempos de cómputo

Las decisiones prácticas de implementación dependen del costo computacional de cada método. Medimos en un sistema típico (CPU Intel, single-thread Python con NumPy/SciPy):

Método	Parámetros	Tiempo (ms)
FD Europeo (CN)	$M = N_t = 100$	~ 3
	$M = N_t = 200$	~ 4
	$M = N_t = 400$	~ 11
PSOR Americano	$M = N_t = 100$	~ 300
	$M = N_t = 200$	$\sim 1,300$
	$M = N_t = 300$	$\sim 3,800$
MC Asiático (vectorizado)	$N_{\text{paths}} = 50,000$	~ 320 (se ≈ 0.025)
	$N_{\text{paths}} = 100,000$	~ 670 (se ≈ 0.018)
	$N_{\text{paths}} = 200,000$	$\sim 1,600$ (se ≈ 0.013)
	$N_{\text{paths}} = 500,000$	$\sim 4,200$ (se ≈ 0.008)

Conclusiones.

- **FD Europeo es $\sim 100\times$ más rápido que PSOR Americano** para la misma malla. La razón: PSOR requiere iteración interna (típicamente 20–100 por paso temporal) hasta converger al complementario.
- **El error de MC decrece como $1/\sqrt{N_{\text{paths}}}$.** Para reducir el error a la mitad hay que cuadruplicar el número de paths. Esto hace que MC sea ineficiente para alta precisión, pero apropiado para problemas multidimensionales donde no hay alternativa.
- **Para problemas regulares (vainilla, pocos regímenes), FD es órdenes de magnitud más eficiente que MC.** MC gana solo cuando la dimensión del espacio de estados crece (e.g., asiática que requiere A_t , opciones path-dependent complejas, cestas).

6.5 Guía rápida: cuándo usar qué método

Situación	Método recomendado	Razón
Europeas, $r_0 = r_1$	Carr–Madan FFT o COS (Taller 1)	Forma cerrada vía función característica; órdenes de magnitud más rápido.
Europeas, $r_0 \neq r_1$	FD con θ -esquema, Crank–Nicolson	FFT/COS dejan de aplicarse. FD acoplado es directo y eficiente.
Americanas (cualquier r)	PSOR sobre PDE acoplada o ecuación integral de Zheng–Zhu	PSOR es robusto pero costoso. Zheng–Zhu es más rápido pero requiere implementación cuidadosa.
Asiáticas (cualquier r)	Monte Carlo	PDE reducida de Rogers–Shi es numéricamente delicada. MC es el estándar industrial.
Greeks (Delta, Gamma)	Diferenciación analítica de la función característica si $r_0 = r_1$; bumping FD en otro caso	Análoga a §6.3 del Taller 2; bumping FD funciona en cualquier caso pero introduce error de truncamiento.
Problemas con $n \geq 3$ regímenes	FD acoplado escalable o método integral generalizado de Zheng–Zhu	PSOR sigue funcionando; expansión cerrada de Putzer requiere fórmulas adicionales.

Ejercicio 19 (reflexión) — Diseño de un sistema de valoración

Una mesa de derivados necesita valorar un libro de opciones con las siguientes características:

- 70% europeas vainilla, ATM, vencimientos cortos ($T < 1$).
- 20% americanas vainilla, vencimientos medios ($T \in [1, 3]$).
- 10% asiáticas, vencimientos largos ($T > 3$).

Diseñe una estrategia de implementación que minimice el tiempo total de cómputo respetando una tolerancia de error ≤ 1 centavo para vainilla y ≤ 5 centavos para path-dependent. Justifique:

1. Qué método aplicaría a cada subconjunto.
2. Qué resoluciones de malla / paths usaría.
3. Qué precomputaciones (matriz $\mathcal{L}$, factorización LU) se pueden reusar entre opciones con el mismo régimen de parámetros.

Resumen. La Sección 6 consolida los resultados de las tres secciones anteriores en escenarios cuantitativos coherentes. La novedad central del Taller 3 ($r_0 \neq r_1$) modifica los precios de manera no trivial y diferenciada por régimen: la put europea del régimen 0 *aumenta* con el spread, la del régimen 1 *disminuye*. La prima americana es mayor en el régimen de alta volatilidad y depende fuertemente del vencimiento. La tabla de tiempos cuantifica el trade-off entre FD (rápido pero limitado en dimensión) y MC (escalable pero costoso para alta precisión). La guía rápida en §6.5 sintetiza las recomendaciones prácticas de implementación.

7. Preguntas de reflexión

Ejercicio 20 — Preguntas conceptuales

Estas preguntas sintetizan los resultados teóricos y prácticos del taller. Las respuestas deben ser cortas (uno o dos párrafos) y explícitas sobre dónde en el taller se cubre el tema.

1. **Acoplamiento por régimen.** Explique por qué la PDE de valoración en el modelo Markov-modulado es *intrínsecamente acoplada* entre regímenes, mientras que en el Taller 2 la función característica permitía un cálculo desacoplado (φ_0^Q y φ_1^Q se calculan independientemente). ¿Qué propiedad estructural del problema permite esa diferencia?
2. **Por qué falla la factorización del descuento.** Cuando $r_0 \neq r_1$, el factor $\exp(-\int_0^T r_{\varepsilon(s)} ds)$ no se factoriza fuera de la esperanza. ¿Cuál es la consecuencia matemática (la función característica deja de ser suficiente para precios) y la consecuencia computacional (los métodos del Taller 2 dejan de aplicarse)? Mencione explícitamente la observación de la frontera $S = 0$ en §3.2 como caso particular degenerado.
3. **El término de acoplamiento en la PDE.** Justifique financieramente el término $\lambda_i(V_{1-i} - V_i)$ en la PDE acoplada (1). Interprete el signo de la contribución cuando $V_{1-i} > V_i$ vs. $V_{1-i} < V_i$.
4. **La elegancia de Putzer.** La Sección 4.4 usa la fórmula cerrada de Putzer para $e^{\tau C(\eta)}$ en 2×2 en lugar del análisis de Jordan general del paper. ¿Cuál es la ventaja para implementación, y cuál la limitación? ¿Cómo se generalizaría a $n = 3$ regímenes?
5. **Por qué Rogers–Shi adaptado al régimen funciona.** Explique en qué propiedad algebraica del acoplamiento $\lambda_i(V_{1-i} - V_i)$ se apoya la reducción $V_i = S \cdot H_i(\xi, t)$. Si el acoplamiento fuera del tipo $\lambda_i V_i V_{1-i}$ (no lineal), ¿qué pasaría con la reducción?
6. **El trade-off PDE vs. Monte Carlo.** Para asiáticas, optamos por Monte Carlo en lugar de FD sobre la PDE reducida. Para europeas y americanas, FD/PSOR son los métodos de elección. ¿Qué característica del problema discrimina cuándo MC es preferible? Discuta el papel del kink, la degeneración del operador, y la dimensión del espacio de estados.
7. **Mezcla de regímenes a horizontes largos.** En la Sección 6.3 se observa que Π_1/Π_0 decrece con T . ¿Qué propiedad ergódica de la cadena de Markov explica esto? Calcule la escala de tiempo característica de mezcla a partir de los autovalores de la matriz generadora Q para los parámetros base ($\lambda_0 = 2$, $\lambda_1 = 5$). ¿Qué horizonte T corresponde a “régimen olvidado”?
8. **Generalización a $n \geq 3$ regímenes.** Discuta qué partes del taller se generalizan inmediatamente y cuáles requieren modificaciones no triviales: (a) la PDE acoplada y FD; (b) PSOR; (c) el método de Zheng–Zhu; (d) Monte Carlo; (e) la reducción de Rogers–Shi.

A. Resumen de fórmulas clave

Modelo y cadena de Markov

Dinámica bajo Q (Sección 2.5)

$$dS_t = S_t r_{\varepsilon(t)} dt + S_t \sigma_{\varepsilon(t)} dW_t^Q, \quad Q = \begin{pmatrix} -\lambda_0 & \lambda_0 \\ \lambda_1 & -\lambda_1 \end{pmatrix}.$$

Distribución estacionaria: $\pi_0 = \lambda_1 / (\lambda_0 + \lambda_1)$, $\pi_1 = \lambda_0 / (\lambda_0 + \lambda_1)$.

PDE acoplada de valoración

Sistema acoplado de Black–Scholes–Markov

$$\frac{\partial V_i}{\partial t} + r_i S \frac{\partial V_i}{\partial S} + \frac{\sigma_i^2 S^2}{2} \frac{\partial^2 V_i}{\partial S^2} + \lambda_i (V_{1-i} - V_i) - r_i V_i = 0, \quad i = 0, 1.$$

Para asiática añadir $+S \partial V_i / \partial A$; para americana imponer además $V_i \geq (K - S)^+$ y *smooth pasting* en la frontera libre $P_i(t)$.

Diferencias finitas: θ -esquema

θ -esquema por bloques (Sección 3)

$$(I_{2M} - \theta \Delta \tau \mathcal{L}) \mathbf{U}^{n+1} = (I_{2M} + (1 - \theta) \Delta \tau \mathcal{L}) \mathbf{U}^n,$$

con $\mathcal{L} = \begin{pmatrix} L_0 & \lambda_0 I \\ \lambda_1 I & L_1 \end{pmatrix}$, L_i tridiagonales con coeficientes

$$a_i^j = \frac{\sigma_i^2 j^2}{2} - \frac{r_{ij}}{2}, \quad b_i^j = -\sigma_i^2 j^2 - r_i - \lambda_i, \quad c_i^j = \frac{\sigma_i^2 j^2}{2} + \frac{r_{ij}}{2}.$$

Valores típicos: $\theta = 1/2$ (Crank–Nicolson, orden $\mathcal{O}((\Delta \tau)^2)$, incondicionalmente estable).

Americanas: ecuación integral de Zheng–Zhu

Adimensionalización y fórmula de Putzer (Sección 4)

Variables adimensionales: $x = \ln(S/K)$, $\tau_i = \sigma_i^2(T - t)/2$, $u_i = V_i/K$, $p_i = \ln(P_i/K)$, $\alpha_i = 2r_i/\sigma_i^2$, $\beta_{ij} = 2\lambda_{ij}/\sigma_i^2$.

Matriz $C(\eta)$ y exponencial cerrada por Putzer (Caso A, raíces distintas):

$$e^{\tau C} = \frac{e^{a_1 \tau} (C - a_2 I) - e^{a_2 \tau} (C - a_1 I)}{a_1 - a_2},$$

con $a_{1,2} = (\text{tr}(C) \pm \sqrt{\text{tr}(C)^2 - 4 \det(C)})/2$. Caso B (raíz doble a): $e^{\tau C} = e^{a \tau} (I + \tau(C - aI))$.

Sistema integral para fronteras óptimas $p_i(\tau_i)$:

$$\frac{1 - e^{p_i(\tau_i)}}{2} = \frac{1}{2\pi} \int_0^{\tau_1} \int_{-\infty}^{+\infty} e^{i\eta p_i(\tau_i)} [e^{(\tau_1-s)C(\eta)} \mathbf{F}(\eta, s)]_i d\eta ds.$$

Asiáticas: reducción de Rogers–Shi

PDE reducida (Sección 5.2)

Cambio de variable $\xi = (KT - A)/S$, $V_i(S, A, t) = S \cdot H_i(\xi, t)$. PDE 1D acoplada:

$$\frac{\partial H_i}{\partial t} + \frac{\sigma_i^2 \xi^2}{2} \frac{\partial^2 H_i}{\partial \xi^2} - (r_i \xi + 1) \frac{\partial H_i}{\partial \xi} + \lambda_i (H_{1-i} - H_i) = 0.$$

Condición terminal $H_i(\xi, T) = (-\xi)^+ / T$. Precio: $V_i(S_0, 0, 0) = S_0 H_i(KT/S_0, 0)$. El término $-r_i V_i$ desaparece por la transformación.

Monte Carlo para asiáticas Markov-moduladas

Estimador MC (Sección 5.4)

$$V_i(S_0, 0, 0) \approx \frac{1}{N_{\text{paths}}} \sum_{k=1}^{N_{\text{paths}}} e^{-D_T^{(k)}} \left(\frac{A_T^{(k)}}{T} - K \right)^+,$$

con $D_T = \int_0^T r_{\varepsilon(s)} ds$ acumulado por suma de Riemann y A_T por trapecio. Transición de régimen: $P(\text{salto en } \Delta t \mid \varepsilon = i) = 1 - e^{-\lambda_i \Delta t}$. Error estándar $\propto 1/\sqrt{N_{\text{paths}}}$.

Cuándo usar qué método (síntesis)

Tipo de opción	Régimen tasas	Método recomendado
Europea	$r_0 = r_1$	FFT / COS (Taller 2)
Europea	$r_0 \neq r_1$	FD acoplado, Crank–Nicolson
Americana	cualquiera	PSOR sobre PDE acoplada
Asiática (arithmetic)	cualquiera	Monte Carlo

Fin del Taller 3.