

Informe del parcial

Calibración del modelo Markov-modulado a opciones de SPY

Julián Alejandro Archila Caro

Snapshot de mercado: 24 de junio de 2026

1 Introducción y modelo

La volatilidad de SPY se modela con una cadena de Markov $\varepsilon(t)$ de dos estados, con parámetros $\theta = (\sigma_0, \sigma_1, \lambda_0, \lambda_1)$. El objetivo es estimar θ a partir de una cadena real de opciones (el problema inverso). La dinámica bajo la medida martingala $\mathbb{Q}$ es

$$dS_t = S_t r dt + S_t \sigma_{\varepsilon(t)} dW_t^{\mathbb{Q}}, \quad Q = \begin{pmatrix} -\lambda_0 & \lambda_0 \\ \lambda_1 & -\lambda_1 \end{pmatrix},$$

con distribución estacionaria $\pi_0 = \lambda_1/(\lambda_0 + \lambda_1)$, $\pi_1 = 1 - \pi_0$.

Se calibra con una **tasa común** $r_0 = r_1 = r$: un solo subyacente da una sola curva de tasa, así que el régimen modula la volatilidad, no la tasa. Con $r_0 = r_1$ el descuento es e^{-rT} y las tres rutas de valoración coinciden, lo que permite validarlas entre sí. Se usan tres: la fórmula analítica por mezcla sobre la varianza integrada (Ruta A, Sección 3), Fourier/COS (Ruta B) y la EDP acoplada (Ruta C). COS es el motor de la calibración (Sección 5).

2 Datos de mercado (Parte 0)

Snapshot congelado. La cadena de opciones de SPY se descargó **una sola vez** con yfinance el 24 de junio de 2026 (22:34 UTC) y se almacenó en `data/spy_options_raw.csv`; toda la calibración corre contra ese archivo, nunca contra una descarga en vivo. El spot fue $S_0 = 733,24$. Se fijó la tasa libre de riesgo $r = 3,69\%$ (T-bill a 13 semanas ^IRX, usado como curva plana coherente con $r_0 = r_1$) y la tasa de dividendos $q = 1,27\%$ (dividendos de los últimos 365 días sobre el spot). Se trabaja con el forward $F = S_0 e^{(r-q)T}$ y conteo de días **ACT/365**; el dividendo se absorbe en el spot ajustado $S_0 e^{-qT}$ dentro del motor de valoración. Se usa el precio `mid = (bid + ask)/2`.

Filtrado determinista. Partiendo de 2497 cotizaciones crudas (calls y puts en siete vencimientos entre 30 y 358 días), se aplican en cascada filtros de liquidez y no arbitraje: `bid/ask` válidos (2472), `mid` $\geq 0,05$ (2395), `spread relativo` $\leq 0,5$ (2389), `volumen` ≥ 1 (2286), `interés abierto` ≥ 10 (1996), `moneyness` $0,8 \leq K/S_0 \leq 1,2$ (1229) y `cotas de no arbitraje` (1217). Las 1217 observaciones finales tienen volatilidad implícita y vega Black-Scholes finitas. La Tabla 1 reporta el número de cotizaciones por vencimiento tras el filtrado.

Vencimiento	30 d	58 d	86 d	114 d	177 d	268 d	358 d	Total
Calls	107	143	140	52	58	58	58	616
Puts	119	144	158	42	45	46	47	601
Total	226	287	298	94	103	104	105	1217

Tabla 1: Cotizaciones por vencimiento y tipo tras el filtrado (1217 en total).

La Figura 1 resume el conjunto: los precios `mid` decaen con el strike, el `spread relativo` se mantiene controlado por el filtro salvo en las alas, y la volatilidad implícita de mercado muestra el **skew** característico de los índices de renta variable (más cara la protección a la baja) y se aplanan al aumentar el plazo.




Figura 1: Exploratorio del snapshot de SPY (calls): precio mid, spread relativo e IV de mercado frente a la moneyness K/S_0 , por vencimiento.

3 Fórmula analítica por mezcla (Parte A)

Condicionando en la varianza integrada $A_{0,T} = \int_0^T \sigma_{\varepsilon(s)}^2 ds$, el log-precio es gaussiano y el precio de la call es exactamente Black–Scholes con varianza total a y tasa integrada $R(a)$. El precio condicionado al régimen inicial i es la mezcla del átomo de «ningún cambio de régimen» y la integral contra la densidad continua:

$$C_i(0, s) = e^{-\lambda_i T} \text{BS}(s, K, T, r(a_i^*); a_i^*) + \int_{a_-}^{a_+} \text{BS}(s, K, T, r(a); a) g_i^A(a, T) da,$$

con soporte $a_- = \sigma_0^2 T$, $a_+ = \sigma_1^2 T$, $a_0^* = a_-$, $a_1^* = a_+$ y $R(a) = r_0 T + (r_1 - r_0)(a - a_-)/\Delta_\sigma$, $\Delta_\sigma = \sigma_1^2 - \sigma_0^2$. Con $r_0 = r_1 = r$ se recupera $R(a) = rT$.

Implementación. Se programa `price_analytic_markov` integrando el término continuo con cuadratura adaptativa (`scipy.integrate.quad`). La densidad g_i^A tiene una singularidad integrable $\sim a^{\mp 1/2}$ en los extremos (vía $I_1(\eta(a))/\sqrt{\cdot}$); se estabiliza con la sustitución $a = c - h \cos t$, que distribuye los nodos hacia los bordes, y se usa `scipy.special.liv` (Bessel escalada) para evitar overflow. El caso singular $\sigma_0 \rightarrow \sigma_1$ ($\Delta_\sigma \rightarrow 0$) se trata con una rama explícita que devuelve Black–Scholes plano. Las puts se obtienen por paridad por régimen.

Pruebas internas. Se verifican cuatro pruebas (Tabla 2). La **masa total** $e^{-\lambda_i T} + \int_{a_-}^{a_+} g_i^A da = 1$ se cumple con error máximo $2,2 \times 10^{-16}$ sobre tres juegos de parámetros y ambos regímenes — muy por debajo del objetivo 10^{-6} . En el **caso singular**, al reducir $\sigma_1 - \sigma_0$ el precio converge monótonamente a la BS plana ($|C_0 - \text{BS}| = 1,4 \times 10^{-8}$ para $\sigma_1 - \sigma_0 = 10^{-9}$) y la rama explícita $\sigma_0 = \sigma_1$ coincide exactamente; además el código rechaza con `ValueError` el caso degenerado con $r_0 \neq r_1$, donde la cota deja de valer. La **cota** $\text{BS}(\cdot; a_-) \leq C_i \leq \text{BS}(\cdot; a_+)$ se cumple en toda una batería de seis casos (calls y puts). La **sanidad financiera** (positividad, no arbitraje, monotonía en K , ausencia de NaN) se satisface, y la paridad call–put por régimen se cumple con residuo $5,3 \times 10^{-15}$.

Prueba	Resultado	Veredicto
Masa total ($\leq 10^{-6}$)	error máx. = $2,2 \times 10^{-16}$	OK
Caso singular $\sigma_0 \rightarrow \sigma_1$	$\rightarrow$ BS plano; rama explícita exacta	OK
Cota $\text{BS}(a_-) \leq C_i \leq \text{BS}(a_+)$	se cumple (6 casos, call+put)	OK
Sanidad (positividad, arbitraje, monotonía)	sin NaN; paridad C-P = $5,3 \times 10^{-15}$	OK

Tabla 2: Pruebas internas de la Ruta A (resumen). Todas dentro de tolerancia.

4 Validación cruzada de las tres rutas (Parte B)

Para confirmar que las tres rutas dan el mismo precio se comparan calls (la EDP, escrita para puts, se pasa a call por paridad). En un caso de prueba ($S_0 = 100$, $T = 0,5$, $r = 0,03$, $\sigma_0 = 0,15$, $\sigma_1 = 0,40$, $\lambda_0 = 2$, $\lambda_1 = 5$) se valoran $K \in \{90, 100, 110\}$ y ambos regímenes con COS ($N = 1024$, $L = 12$), FFT de control ($N = 2^{16}$, $\alpha = 1,5$, $\eta = 0,05$) y la EDP Crank–Nicolson ($M = N_t = 800$, $\theta = 1/2$). La Tabla 3 muestra coincidencia total.

Rég.	K	Ruta A	B (COS)	C (EDP)	$ A-B $	$ A-C $
0	90	13,198930	13,198930	13,198416	$3,0 \times 10^{-14}$	$5,2 \times 10^{-4}$
0	100	6,776006	6,776006	6,775109	$4,7 \times 10^{-14}$	$9,0 \times 10^{-4}$
0	110	3,051285	3,051285	3,051190	$1,8 \times 10^{-13}$	$9,5 \times 10^{-5}$
1	90	14,725176	14,725176	14,724686	$2,0 \times 10^{-12}$	$4,9 \times 10^{-4}$
1	100	8,865638	8,865638	8,865001	$1,0 \times 10^{-13}$	$6,4 \times 10^{-4}$
1	110	5,002082	5,002082	5,001940	$1,5 \times 10^{-13}$	$1,4 \times 10^{-4}$

Tabla 3: Validación A/B/C, caso base. Precios call y diferencias absolutas máximas. Tolerancia objetivo 10^{-3} .

Los máximos son $\max|A-B| = 2,0 \times 10^{-12}$ y $\max|A-C| = \max|B-C| = 9,0 \times 10^{-4}$: todas las diferencias quedan $\leq 10^{-3}$. La validación se repitió en un segundo caso ($T = 1,0$, $r = 0,05$, $\sigma_0 = 0,20$, $\sigma_1 = 0,55$, $\lambda_0 = 3$, $\lambda_1 = 1,5$), con $\max|A-C| = 3,0 \times 10^{-4}$, para no validar sobre un único punto.

Diagnóstico de error. La concordancia A-B a nivel de 10^{-12} confirma que la fórmula analítica y COS comparten la misma función característica (verificada además contra la exponencial matricial, error $3,9 \times 10^{-16}$). La fuente **dominante** de discrepancia es la **discretización de la EDP**: un estudio de convergencia ($M = N_t \in \{50, \dots, 800\}$) muestra que el error frente a la Ruta A cae de $2,3 \times 10^{-1}$ a $9,0 \times 10^{-4}$ con razón ≈ 4 al duplicar la malla, es decir orden 2 en espacio/tiempo, consistente con Crank–Nicolson. COS, en cambio, es estable: al refinar N el precio no cambia más de $1,2 \times 10^{-7}$. La cuadratura de A y el truncamiento espectral de B/COS aportan errores varios órdenes por debajo.

Elección del motor. Los tiempos por evaluación (tres strikes) son COS 0,54 ms, Ruta A 20,1 ms y EDP 109,9 ms: COS es $\approx 37 \times$ más rápido que A y $\approx 202 \times$ más rápido que la EDP. Por velocidad y estabilidad, **COS es el motor dentro del bucle de calibración**, reservando A y la EDP para verificaciones puntuales del ajuste final.

5 Calibración a datos reales (Parte C)

Precio del modelo y objetivo. Como el régimen inicial $\varepsilon(0)$ no se observa, el precio de mercado se modela con la mezcla estacionaria $C^{\text{mod}} = \pi_0 C_0 + \pi_1 C_1$. El objetivo es el **RMSE en volatilidad implícita**, más estable que en precios porque homogeneiza escalas a través de strikes y vencimientos. Se comparan dos esquemas de **ponderación**: uniforme y por **vega** (privilegia las cotizaciones con mayor contenido informativo). La cadena se agrupa por vencimiento para reutilizar evaluaciones COS y la IV del modelo se invierte con un Newton vectorizado (error $\leq 2,4 \times 10^{-9}$ frente a Brent).

Simetría y restricciones. La simetría de etiqueta $(\sigma_0, \lambda_0) \leftrightarrow (\sigma_1, \lambda_1)$ se rompe con una **reparametrización logística acotada** $\theta(u)$, $u \in \mathbb{R}^4$, que garantiza por construcción $0 < \sigma_0 < \sigma_1$ y $\lambda_i > 0$ sin penalizaciones discontinuas (round-trip $\theta \rightarrow u \rightarrow \theta$ con error 9×10^{-16}). Los techos $\sigma_0 < 0,60$, $\sigma_1 < 0,90$ y $0,05 < \lambda_i < 20$ son económicos: $\sigma_1 = 90\%$ es un nivel de estrés histórico del SPY.

Tres optimizadores. (i) **Búsqueda exhaustiva en malla** $5 \times 5 \times 4 \times 4 = 400$ nodos sobre una caja; (ii) **Nelder–Mead** (sin gradiente); y (iii) **BFGS** (gradiente por diferencias finitas). Los métodos locales parten del mejor nodo de la malla. La Tabla 4 reporta las seis corridas (tres técnicas $\times$ dos ponderaciones).

Método	Pesos	$\hat{\sigma}_0$	$\hat{\sigma}_1$	$\hat{\lambda}_0$	$\hat{\lambda}_1$	RMSE	Estado
Malla	unif.	0,1125	0,7250	0,500	8,000	0,05127	malla
Nelder–Mead	unif.	0,1054	0,9000	0,364	6,701	0,05007	conv.
BFGS	unif.	0,1054	0,9000	0,363	6,687	0,05007	conv.
Malla	vega	0,0500	0,9000	0,500	5,500	0,04262	malla
Nelder–Mead	vega	0,0852	0,9000	0,315	3,931	0,04111	conv.
BFGS	vega	0,0852	0,9000	0,315	3,931	0,04111	conv.

Tabla 4: Calibración: tres técnicas $\times$ dos ponderaciones. RMSE en IV. La solución final se resalta.

Sensibilidad al punto inicial. Para cada técnica y ponderación se probaron arranques adicionales (malla y un punto «razonable»). El RMSE final coincide entre arranques con dispersión $\leq 10^{-7}$ y $\max|\theta - \bar{\theta}| \leq 8 \times 10^{-3}$ en las intensidades: dentro de cada cuenca el óptimo es robusto al inicio.

Solución final. La ponderación primaria (**vega**) se fija *ex ante* — no es válido elegir entre objetivos distintos comparando sus RMSE. Entre los candidatos factibles, BFGS y Nelder–Mead coinciden; se reporta

$$\hat{\theta} = (\hat{\sigma}_0, \hat{\sigma}_1, \hat{\lambda}_0, \hat{\lambda}_1) = (0,0852, 0,9000, 0,3151, 3,9308), \quad \text{RMSE}_{IV} = 0,0411,$$

con mezcla estacionaria $\pi_0 = 0,926$, $\pi_1 = 0,074$. **Verificación con la Ruta A:** recalculando cuatro precios del ajuste final con la fórmula analítica frente a COS, la diferencia absoluta máxima es $2,6 \times 10^{-3}$ y la relativa $1,8 \times 10^{-4}$, confirmando la consistencia del motor de calibración.

5.1 Diagnóstico e identificabilidad

Para distinguir tolerancia del optimizador de cuencas distintas se evalúa el RMSE sobre la recta $\theta(\alpha) = \alpha\hat{\theta}_1 + (1 - \alpha)\hat{\theta}_2$, $\alpha \in (-0,5, 1,5)$ (Figura 2). El corte **mallá vs. BFGS** es una U suave con un único mínimo en el extremo $\alpha = 0$ (BFGS), y **Nelder–Mead vs. BFGS** es plano entre ambos (coinciden): no hay mínimos separados, de modo que las soluciones viven en una **cuenca común** y difieren sólo por tolerancia. La caída abrupta a la izquierda en el panel derecho marca la frontera de factibilidad ($\sigma_0 < \sigma_1$ violado), correctamente recortada.




Figura 2: RMSE(IV) sobre cortes afines $\theta(\alpha)$ entre pares de soluciones. U suave y tramo plano $\rightarrow$ cuenca común; el escalón marca la región infactible recortada.

Los **perfiles 1D** alrededor del óptimo (Figura 3) precisan qué direcciones están bien determinadas. σ_0 , λ_0 y λ_1 exhiben mínimos interiores claros (bien identificados localmente), mientras que el perfil de σ_1 es **monótonamente decreciente** hasta la cota 0,90: el objetivo es casi plano en σ_1 por arriba y el óptimo se apoya en el techo. En consecuencia, no se reporta un Hessiano centrado (la cota está activa) y σ_1 **se interpreta como dirección no identificada por arriba**: los datos fijan la *existencia* de un segundo régimen más volátil, no su nivel exacto.

Perfiles 1D del RMSE alrededor del óptimo final




Figura 3: Perfiles 1D del RMSE alrededor del óptimo. σ_0 , λ_0 , λ_1 con mínimo interior; σ_1 monótono hasta la cota (dirección débilmente identificada).

6 Comparación con Black–Scholes y análisis económico (Parte D)

Sonrisa y residuos. La Figura 4 superpone la IV de mercado y la del modelo por vencimiento. El modelo de mezcla reproduce el **nivel** y la **curvatura** (forma de U) de la sonrisa, pero al combinar dos volatilidades con drift puro genera una sonrisa casi simétrica y no captura del todo el **skew asimétrico** de la renta variable. Los residuos (Figura 5) muestran un patrón en S frente a la moneyness que se atenúa con el plazo: el RMSE por vencimiento baja de 0,061 (30 d) a 0,038 (358 d) y el sesgo medio pasa de +0,024 a −0,007, coherente con que a horizontes largos domina la mezcla estacionaria.




Figura 4: Sonrisa de IV: mercado (puntos) vs. modelo de regímenes (línea), por vencimiento.




Figura 5: Residuos de IV (modelo — mercado) por moneyness (color = T) y distribución por vencimiento. El patrón en S se atenúa al crecer T .

Régimen vs. Black-Scholes plano. Calibrado un único σ de BS sobre la misma cadena y criterio, con ponderación vega se obtiene $\sigma^* = 0,196$ y $\text{RMSE} = 0,0565$, frente a $0,0411$ del modelo de regímenes: una **mejora del 27,2%** en RMSE de IV. Los dos parámetros efectivos extra (dado que σ_1 y una de las λ están débilmente fijados) se justifican porque BS plano produce una IV constante incapaz de reproducir cualquier curvatura, mientras que la mezcla sí la genera.

Estructura a plazo. Recalibrando cada vencimiento por separado (Figura 6), σ_0 es estable ($\text{CV} \approx 12\%$, suave descenso de $0,115$ a $0,079$) pero σ_1 se pega a la cota en *todos* los plazos y λ_0 al piso, mientras λ_1 decae de $0,85$ a $0,37$. La calibración conjunta usa más información y promedia estas tensiones, pero sigue siendo un compromiso de parámetros constantes; que las cotas estén activas en todos los plazos confirma la identificación débil más que un verdadero cambio temporal.




Figura 6: Estabilidad a plazo: calibración separada (puntos) vs. conjunta (líneas) para volatilidades (izq.) e intensidades (der.).

Interpretación económica. El óptimo describe un mercado que pasa la mayor parte del tiempo en calma: $\sigma_0 = 8,5\%$ frente a $\sigma_1 = 90\%$ de estrés, con probabilidades estacionarias $\pi_0 = 92,6\%$ y $\pi_1 = 7,4\%$. Las duraciones esperadas son $1/\lambda_0 = 3,17$ años en calma y $1/\lambda_1 = 0,25$ años (≈ 64 días hábiles) en crisis: episodios de estrés cortos e infrecuentes pero intensos, razonable para SPY. El segundo autovalor de Q es $-(\lambda_0 + \lambda_1) = -4,25$, con **tiempo de mezcla** $1/(\lambda_0 + \lambda_1) = 0,24$ años (≈ 59 días hábiles); más allá de $\approx 3t_{\text{mix}} = 0,71$ años el peso del régimen inicial decae a $\sim 5\%$ y la valoración queda gobernada por la mezcla estacionaria.

6.1 Respuestas a las preguntas de la Parte D

1. **Identificabilidad.** σ_0 es la dirección mejor determinada porque fija el nivel principal de la sonrisa (perfil con mínimo agudo). Las intensidades identifican mejor el cociente estacionario $\pi_0 = \lambda_1/(\lambda_0 + \lambda_1)$ que λ_0, λ_1 por separado. σ_1 está mal determinado por arriba: su perfil es monótono hasta la cota (Figura 3) y el óptimo se apoya en ella, síntoma del mal condicionamiento del problema inverso (superficie casi plana).
2. **Por qué $r_0 = r_1$.** Las opciones ven el descuento sólo a través del bono $\mathbb{E}_i[e^{-\int_0^T r}]$, que un único subyacente fija como una sola curva. Con $r_0 = r_1$ el descuento se factoriza como e^{-rT} y las tres rutas aplican; con $r_0 \neq r_1$ el descuento depende del camino (de los tiempos de ocupación) y no se factoriza, por lo que COS deja de valer. Aun cuando la fórmula cerrada y la EDP admiten dos tasas, éstas no son identificables a partir de un solo subyacente: harían falta instrumentos sensibles a la tasa por régimen (renta fija o derivados de tasas).
3. **Régimen vs. Black–Scholes plano.** El modelo de regímenes reduce el RMSE de IV un 27% frente a BS plano (0,0411 vs. 0,0565). La mejora es material y justifica el modelo, con la salvedad de que parte de la ganancia proviene de σ_0 y del cociente estacionario, no de un σ_1 identificado con precisión.
4. **Estructura a plazo.** σ_0 permanece estable a través de los plazos; σ_1 y una intensidad tocan sus cotas en todos los vencimientos (Figura 6). La calibración conjunta es un compromiso razonable, pero los parámetros constantes no absorben por completo la variación del skew con el plazo (residuos decrecientes en T).
5. **Interpretación económica.** $\sigma_0 = 8,5\%$ (calma) y $\sigma_1 = 90\%$ (estrés); $1/\lambda_i$ son las duraciones medias (3,17 y 0,25 años) y π_i las frecuencias de largo plazo (92,6% / 7,4%). σ_1 se acerca a niveles de crisis observados, pero al ser una cota activa debe leerse como cota, no como nivel estimado con precisión.
6. **Horizonte de mezcla.** El efecto del régimen inicial decae como $e^{-(\lambda_0 + \lambda_1)T}$, con $t_{\text{mix}} = 1/(\lambda_0 + \lambda_1) = 0,24$ años. Cerca de $3t_{\text{mix}} \approx 0,71$ años queda $\sim 5\%$ del efecto inicial; a partir de ese horizonte el modelo «olvida» el régimen de arranque y domina la mezcla estacionaria.

7 Conclusiones

La fórmula analítica por mezcla pasa las cuatro pruebas internas (masa con error 10^{-16} , caso singular, cota y sanidad), coincide con COS a nivel de 10^{-12} y con la EDP dentro de 10^{-3} , con el error dominado por la discretización de Crank–Nicolson (orden 2). La calibración a 1217 opciones de SPY con los tres optimizadores

converge a una misma cuenca y reduce el RMSE de IV un 27% frente a Black–Scholes plano. La lectura económica es coherente: calma persistente interrumpida por crisis cortas e intensas.

La limitación principal es que el objetivo es casi plano en σ_1 , que se apoya en la cota de 90%. Los datos fijan la existencia de un segundo régimen volátil, no su nivel exacto, y λ_1 es la dirección menos estable. El modelo reproduce el nivel y la curvatura de la sonrisa, pero no su asimetría: es lo esperable de un modelo de volatilidad con drift puro frente al skew de la renta variable.